

Kierunek: **TAI**
Specjalność: **-**

PRACA DYPLOMOWA
MAGISTERSKA

Opracowanie algorytmów uczenia maszynowego w
badaniach stereoEEG

Michał Dams

Opiekun pracy
dr inż. Łukasz Jeleń

Słowa kluczowe: Uczenie maszynowe, Sztuczna Inteligencja, StereoEEG

Streszczenie

Celem niniejszej pracy było opracowanie modeli uczenia maszynowego wykorzystujących dane zgromadzone w ramach badania pupilometrycznego oraz stereoEEG. Przeznaczeniem modeli było rozpoznanie prawidłowego enkodowania oraz dekodowania pamięci u ludzi na podstawie wymienionych biomarkerów. Modele zostały podzielone na 2 typy ze względu na rodzaj danych wykorzystanych do obliczania predykcji skuteczności enkodowania pamięci. Pierwszą grupą były modele uczone tylko na podstawie danych z pupilometrii. Drugą grupę modeli przystosowano do pracy na danych stereoEEG. Dodatkowo zbadano wpływ lokalizacji elektrod w strukturach mózgu na wyniki predykcji. Projekt został zwieńczony analizą porównawczą wymienionych typów modeli uczenia maszynowego.

Abstract

The aim of this study was to develop machine learning models based on data collected from pupillometry and stereoEEG in the learning process. The purpose of the models was to identify the correct encoding and decoding of memory among humans based on the mentioned biomarkers. The models were divided into 2 types based on the type of data used to calculate the prediction of memory encoding efficiency. The first group were models learned only from pupillometry data. Second group of models was adjusted to work on stereoEEG data. The second group of models was adapted to work on stereoEEG data. In addition, the effect of the location of electrodes in brain structures on the prediction results was investigated. The project was concluded with a comparative analysis of the mentioned types of machine learning models.

Spis treści

1	Wstęp	1
1.1	Cele i zakres pracy dyplomowej	2
1.2	Konspekt pracy dyplomowej	3
2	Przegląd literatury	5
2.1	Stereotaktyczna elektroencefalografia	6
2.1.1	Uczenie maszynowe w medycynie	7
2.1.2	Podział algorytmów uczenia maszynowego	8
2.1.3	Zastosowania uczenia maszynowego w analizie danych z badań iEEG	9
2.1.4	Ograniczenia uczenia maszynowego w analizie badań iEEG	12
2.1.5	Wstępne przetwarzanie danych	13
2.1.6	Lokalizacja aktywności epileptycznej w danych iEEG	15
2.2	Pupilometria	15
2.2.1	Charakterystyka badania	15
2.2.2	Wstępne przetwarzanie danych	15
2.2.3	Zastosowanie uczenia maszynowego w analizie danych z pupilometrii	16
2.3	Kodowanie pamięci	16
2.3.1	Korzyści z badań	17
2.3.2	Zastosowanie sEEG do badań nad kodowaniem pamięci	17
2.3.3	Zastosowanie pupilometrii do badań nad kodowaniem pamięci	17
3	Dane i ich wstępne przygotowanie	19
3.1	Rejestrowanie danych	19
3.1.1	iEEG	19
3.1.2	Pupilometria	20
3.1.3	Format danych	20
3.1.4	Rekordy danych	21
3.1.5	Walidacja techniczna	22
3.1.6	Ograniczenia zbioru danych	22
3.1.7	Uwagi dotyczące użytkowania	23
3.2	Zadania pamięciowe	23
3.3	Wstępne przygotowanie danych	25
3.3.1	Identyfikacja miarodajnych kanałów	25
3.3.2	Identyfikacja zdarzeń epileptycznych w sygnałach iEEG	26
3.3.3	Ekstrakcja fragmentów sygnałów związanych z enkodowaniem	26
3.3.4	Dobór szerokości fragmentu	27

3.3.5	Tworzenie etykiet wydarzeń	27
3.3.6	Eliminacja artefaktów związanych z mruganiem i uwarunkowaniami klinicznymi	27
3.3.7	Zmniejszenie częstotliwości próbkowania	28
3.3.8	Normalizacja Z-score	29
3.3.9	Filtrowanie danych	29
4	Implementacja i trening modeli uczenia maszynowego.	31
4.1	Dobór i ekstrakcja cech	31
4.1.1	StereoEEG	31
4.1.2	Pupilometria	32
4.2	Trening modeli	32
4.2.1	Balansowanie liczebności klas	33
4.2.2	Standaryzacja danych	33
4.2.3	Dobór modeli	33
4.2.4	Dane treningowe	33
4.2.5	Impakt lokalizacji elektrod w strukturze mózgu na efektywność algoryt- mów uczenia maszynowego	34
5	Prezentacja i analiza wyników	35
5.1	Osiągi modeli uczenia maszynowego na danych sEEG	35
5.2	Osiągi modeli uczenia maszynowego na danych z pupilometrii	37
5.3	Wydajność modelu MLP w zależności od regionu mózgu, z którego pozyskano dane	39
6	Wnioski końcowe	43
6.1	Obszar potencjalnego zastosowania pracy	44
6.2	Przyszłe kierunki badań	44
	Bibliography	49

1. Wstęp

Ludzie często zapominają informacje, ponieważ nie udaje im się ich skutecznie zakodować. Obecnie bada się różne sposoby stymulacji mózgu, próbując poprawić jego wydajność w zakresie zapamiętywania informacji [12, 16, 42]. Jednym z ważnych elementów tych badań jest zastosowanie algorytmów predykcji kodowania pamięci. Należą one do szeroko pojętego obszaru sztucznej inteligencji – uczenia maszynowego. Algorytmy te są istotne z różnych powodów, głównie związanych z rozumieniem, modelowaniem i potencjalnym usprawnianiem procesów pamięciowych człowieka [4, 18, 29, 31]. Zazwyczaj operują one na różnych typach danych zebranych podczas neuroobrazowania pacjentów za pomocą badań takich jak EEG [19, 44] (elektroencefalografia), sEEG [13] (stereo-elektroencefalografia), ECoG [18] (elektrokortygrafia), fMRI [3] (funkcjonalny rezonans magnetyczny), MEG [44] (magnetoencefalografia), czy TK [46] (tomografia komputerowa). Spośród wymienionych badań, jedne z najbardziej obiecujących wyników uzyskiwane są przez analizę danych pozyskanych podczas badań sEEG.

StereoEEG, czyli stereo-elektroencefalografia jest inwazyjną metodą badania, która polega na wprowadzeniu do mózgu pacjenta cienkich elektrod pozwalających na precyzyjne rejestrowanie aktywności elektrycznej w różnych obszarach mózgu. Główną zaletą sEEG jest dostęp do aktywności w głębokich strukturach korowych i bruzdach. Kontakty elektrod sEEG przebiegają zarówno przez istotę szarą, jak i białą, co wymaga uwzględnienia podczas analizy sygnału i interpretacji danych. Ponadto elektrody mogą pozostać w mózgu przez kilka dni lub tygodni, co pozwala na długotrwałe monitorowanie aktywności mózgu.

Niestety z uwagi na inwazyjność badania, powodującą stałe ubytki na zdrowiu pacjenta, ryzyko powikłań, takich jak infekcje, krwotoki czy uszkodzenie mózgu, a także stopień skomplikowania całej procedury oraz dyskomfort osoby badanej, sEEG wykonuje się niezwykle rzadko i tylko gdy jest to wysoce uzasadnienie kliniczne. W praktyce najczęściej stosuje się je w diagnostyce i leczeniu ogniskowej padaczki lekoopornej, wtedy, gdy mniej inwazyjne metody, takie jak EEG czy MEG nie są wystarczająco efektywne. Poza wartością kliniczną uzyskane sygnały stanowią unikalną możliwość badania procesów fizjologicznych w mózgu człowieka, w tym związanych z pamięcią i zdolnościami poznawczymi [11, 14, 24]. Dodatkowym utrudnieniem w wypadku pracy na danych pozyskanych przy okazji diagnostyki pacjentów chorych na padaczkę lekooporną jest konieczność identyfikacji i pominięcia sygnałów zarejestrowanych podczas aktywności epileptycznej w przypadku generalizacji badań do mózgow zdrowych.

Najnowsze prace naukowe zwracają uwagę na możliwość wykorzystania pupilometrii do badań nad procesami pamięciowymi człowieka [5, 21]. Pupilometria jest techniką pomiaru zmian rozmiaru źrenicy oka. Wielkość źrenicy została powiązana z procesami poznawczymi leżącymi u podstaw percepcji, uwagi i działania na bodźce zewnętrzne. Może ona stanowić łatwo dostępny i nieinwazyjny biomarker sprawności pamięci oraz stanów poznawczych człowieka. Biomarker jest miarą biologicznego stanu zdrowia i może dostarczyć informacji na temat

normalnych, czy patologicznych procesów biologicznych lub reakcji organizmu na różnorakie bodźce.

Przy założeniu, że skuteczność modeli uczenia maszynowego w oparciu o dane z pupilometrii w predykcji poprawnego enkodowania informacji w ludzkim mózgu będzie zbliżona do skuteczności modeli opartych na danych z badań stereoEEG, przyszłe badania nad rozumieniem, modelowaniem oraz potencjalnym usprawnianiem procesów pamięciowych człowieka zostałyby znacząco ułatwione. Łatwość pomiaru i nieinwazyjność badania szerokości źrenicy w porównaniu z wadami sEEG pozwoliłaby na spopularyzowanie oraz przyspieszenie samych badań.

1.1. Cele i zakres pracy dyplomowej

Głównym celem pracy było opracowanie modeli uczenia maszynowego służących do predykcji skuteczności enkodowania informacji w ludzkiej pamięci. Modele wytrenowane zostały kolejno na danych z sEEG oraz pupilometrii. Kolejnym z celów było opracowanie analizy porównawczej opracowanych modeli oraz zestawienie ich skuteczności w predykcji poprawnego enkodowania informacji. Ponadto zbadano dane zarejestrowane w różnych strukturach mózgu pod względem skuteczności predykcji.

Do spełnienia wyznaczonych celów niezbędne było wykonanie następujących etapów pracy:

- Przegląd literatury dotyczącej enkodowania pamięci, pupilometrii, sEEG i stosowania uczenia maszynowego w tych kontekstach.
- Zebranie i przygotowanie danych: zebranie danych z badań sEEG i pupilometrii (istotne dla analizy porównawczej jest, aby badania te były przeprowadzane u pacjentów równocześnie). W danych z badania sEEG: identyfikacja kanałów, które pokazują wartościowe informacje, referencja sygnałów, podział na epoki, odszumianie, usuwanie trendu i filtrowanie częstotliwości danych. W danych pozyskanych z pupilometrii: wykluczenie artefaktów powstałych przez mruganie oraz warunki kliniczne takie jak ruch pacjenta spowodowany bólem lub dyskomfortem.
- Identyfikacja i pominięcie sygnałów zarejestrowanych podczas aktywności epileptycznej w danych z sEEG.
- Budowa i dobór parametrów modeli: Budowa różnych modeli uczenia maszynowego, które będą trenowane na danych z pupilometrii oraz sEEG.
- Trening i testowanie modeli: Trening modeli na różnych typach danych. Ocena modeli na podstawie ich zdolności do skutecznej predykcji skuteczności kodowania pamięci.
- Analiza porównawcza: zestawienie efektywności różnych modeli uczenia maszynowego, które zostały wytrenowane na różnorodnych typach danych.

- Interpretacja i prezentacja wyników: obejmuje zrozumienie, dlaczego niektóre modele działają lepiej niż inne, oraz które cechy są najważniejsze dla skutecznej predykcji skuteczności enkodowania pamięci.
- Postawienie wniosku dotyczącego potencjału pupilometrii w badaniach nad ludzkim procesem zapamiętywania.

1.2. Konspekt pracy dyplomowej

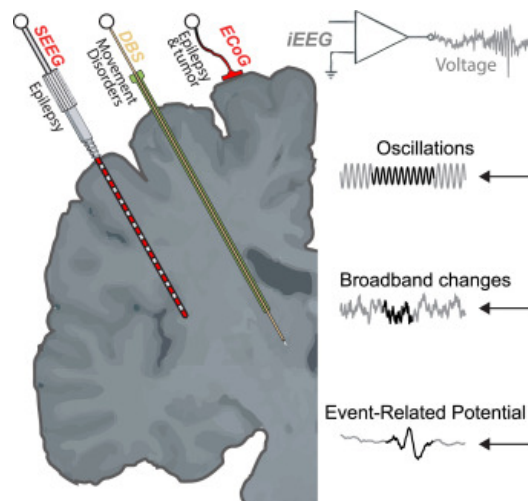
Praca dzieli się wstęp, przegląd literatury, trzy rozdziały stanowiące rdzeń dokumentu oraz zakończenie, na które składa się podsumowanie, wnioski końcowe wynikające z pracy oraz przyszłe możliwe kierunki badań. Pierwszy z trzech rozdziałów stanowiących kluczową część pracy w pełni pokrywa temat danych wykorzystanych w projekcie, w którym zawiera się ich pozyskanie, charakterystyka oraz niezbędne przetwarzanie wstępne. W rozdziale drugim przedstawione zostały metody implementacji, charakterystyka oraz proces treningu modeli uczenia maszynowego. Rozdział trzeci zawiera rezultaty pracy wraz z analizą porównawczą zaimplementowanych algorytmów. Dodatkowo dokument zawiera streszczenie, spis treści, bibliografię, spis tabel oraz spis rysunków.

2. Przegląd literatury

Analizując ilość publikowanych prac naukowych skupionych wokół elektroencefalografii wewnątrzczaszkowej (iEEG) w ostatnich latach widać rosnące zainteresowanie tym typem badań. Postępy w tej dziedzinie oraz neurofizjologii umożliwiły badanie wcześniej niedostępnych regionów mózgu z wysoką rozdzielczością czasową i przestrzenną. Oprócz wartości klinicznej, sygnały uzyskane przy tych badaniach stwarzają unikalną możliwość badania procesów fizjologicznych w ludzkim mózgu [30]. Do kategorii badań elektroencefalografii wewnątrzczaszkowej należą następujące 3 rodzaje badań:

- Elektrokortykografia (ECoG): ta technika polega na umieszczeniu siatki elektrod bezpośrednio na powierzchni mózgu, zwykle podczas operacji neurochirurgicznej. ECoG jest często używany do lokalizacji ogniska padaczki u pacjentów, którzy są kandydatami do operacji.
- Stereotaktyczna elektroencefalografia (sEEG): w tej technice elektrody są umieszczane wewnątrz mózgu, co pozwala na dokładniejsze badanie głębokich struktur mózgu. sEEG jest również często stosowany w kontekście przedoperacyjnej lokalizacji ognisk padaczki.
- Badania z użyciem głębokich elektrod mózgowych (DBS): chociaż te badania są najczęściej używane w kontekście terapii stymulacji głębokich struktur mózgu (na przykład w leczeniu choroby Parkinsona), czasem są one również używane do badania aktywności elektrycznej mózgu.

Rysunek 2.1 przedstawia umiejscowienie elektrod w mózgu dla każdej z wymienionych metod.




Rysunek 2.1: Podkategorie iEEG

Źródło: <https://www.sciencedirect.com/science/article/pii/S1053811922005559>

Wszystkie te techniki mają na celu rejestrację aktywności elektrycznej mózgu z dużą precyzją czasową i przestrzenną, co pozwala na szczegółowe badanie procesów neuronalnych zachodzących w mózgu. Analiza danych zebranych podczas tych badań jest dość podobna, ponieważ techniki te polegają na rejestrowaniu aktywności elektrycznej mózgu. W każdym z przypadków dane są zbierane jako serie pomiarów potencjałów elektrycznych w różnych punktach w mózgu, a następnie są analizowane za pomocą różnych technik przetwarzania sygnałów i analizy danych.

Dotychczas w wielu publikacjach zastosowano uczenie maszynowe do badań iEEG, ale świadomość lekarzy na temat tych technik i ich znaczenia w neurochirurgii jest ograniczona. Obecny stan rzeczy może ulec zmianie w krótkiej perspektywie czasu, jako że widoczna jest mocna tendencja wzrostowa liczby nowych prac w tym temacie (rysunek 2.2), a także popularność algorytmów uczenia maszynowego w dziedzinie medycy rośnie błyskawicznie. Postęp prac jest spowalniany przez trudną dostępność danych z badań sEEG, DBS oraz badań im towarzyszących. Dobrze zorganizowane zbiory danych są krytyczne dla szybkiego udostępniania i eksploracji danych iEEG. Niestety wciąż mało jest dostępnych publicznie wartościowych zbiorów danych w tej dziedzinie.



Rysunek 2.2: Wzrost liczby publikacji dotyczących iEEG w latach 1975-2015

Źródło: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC6476542/>

2.1. Stereotaktyczna elektroencefalografia

Stereo-elektroencefalografia (sEEG) należy do grupy badań określanych mianem elektroencefalografii wewnątrzczaszkowej (ang. Intracranial Electroencephalography), w skrócie iEEG. Jest to technika stosowana w neurologii, która polega na bezpośrednim umieszczaniu

elektrod (zazwyczaj kilkunastu) wewnątrz mózgu w celu rejestrowania aktywności elektrycznej neuronów.


SEEG to inwazyjna metoda stosowana głównie w diagnozowaniu i leczeniu epilepsji lekoopornej. Cienkie elektrody umieszczane są w strukturach mózgu, podejrzanych o generowanie napadów epileptycznych. Elektrody te są umieszczane za pomocą stereotaktycznej techniki, co oznacza, że są precyzyjnie umieszczane w określonych lokalizacjach w mózgu, zgodnie z trójwymiarowym planem. Ta technika umożliwia dokładne zlokalizowanie aktywności elektrycznej w mózgu, której można użyć do identyfikacji obszarów mózgu, które generują napady.

Podczas procedury sEEG, pacjent jest pod ścisłym nadzorem w szpitalu, a jego aktywność mózgowa jest monitorowana przez kilka dni lub nawet tygodni. Te dane są następnie analizowane, aby pomóc lekarzom zrozumieć, jakie obszary mózgu są odpowiedzialne za napady, co może prowadzić do bardziej skierowanego leczenia, takiego jak chirurgiczne wycięcie nieprawidłowo funkcjonującej części mózgu.

Jednym z kluczowych aspektów sEEG jest to, że pozwala na badanie głębokich struktur mózgu, które są niemożliwe do osiągnięcia za pomocą innych metod. Jest to decydujący czynnik w przypadku pacjentów z niekontrolowaną epilepsją, u których konwencjonalne metody leczenia okazały się nieskuteczne. Jednocześnie SEEG oferuje wyjątkowe możliwości w zakresie badań neurofizjologii poznawczej i może odgrywać ważną rolę w badaniach nad ludzkim mózgiem.

2.1.1. Uczenie maszynowe w medycynie

Uczenie maszynowe (ML) to szybko rozwijająca się dziedzina, która wykazała znaczny potencjał w złożonych zastosowaniach biomedycznych [36]. Uczenie maszynowe odnosi się do algorytmów, które mogą podejmować pozornie inteligentne decyzje po zidentyfikowaniu i wyciągnięciu wniosków z ukrytych wzorców w obszernych wcześniej zebranych bazach danych. Szkolenie tych algorytmów na dużych biologicznych zbiorach danych umożliwiło identyfikację złożonych wzorców niezauważalnych dla ludzkich ekspertów. Przykładami pomyślnego wdrożenia uczenia maszynowego w medycynie mogą być algorytmy diagnostyczne w radiologii [43], czy kolonoskopii [49]. Kluczową cechą zaawansowanych algorytmów uczenia maszynowego ograniczających ich użycie w medycynie jest ograniczona "wyjaśnialność". Wyjaśnialność, odnosi się do możliwości zapewnienia użytkownikom systemu AI zrozumienia skąd pochodzą rezultaty przedstawiane przez algorytmy. Algorytmy określane mianem sieci neuronowych często określane są mianem "czarnej skrzynki", gdzie znane są dane wejściowe i wynik działań, ale nie wiadomo, w jaki sposób algorytm uzyskał określony rezultat.



Rysunek 2.3: Udział poszczególnych typów algorytmów uczenia maszynowego w analizie danych z badań iEEG.

Źródło: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC9271576/>

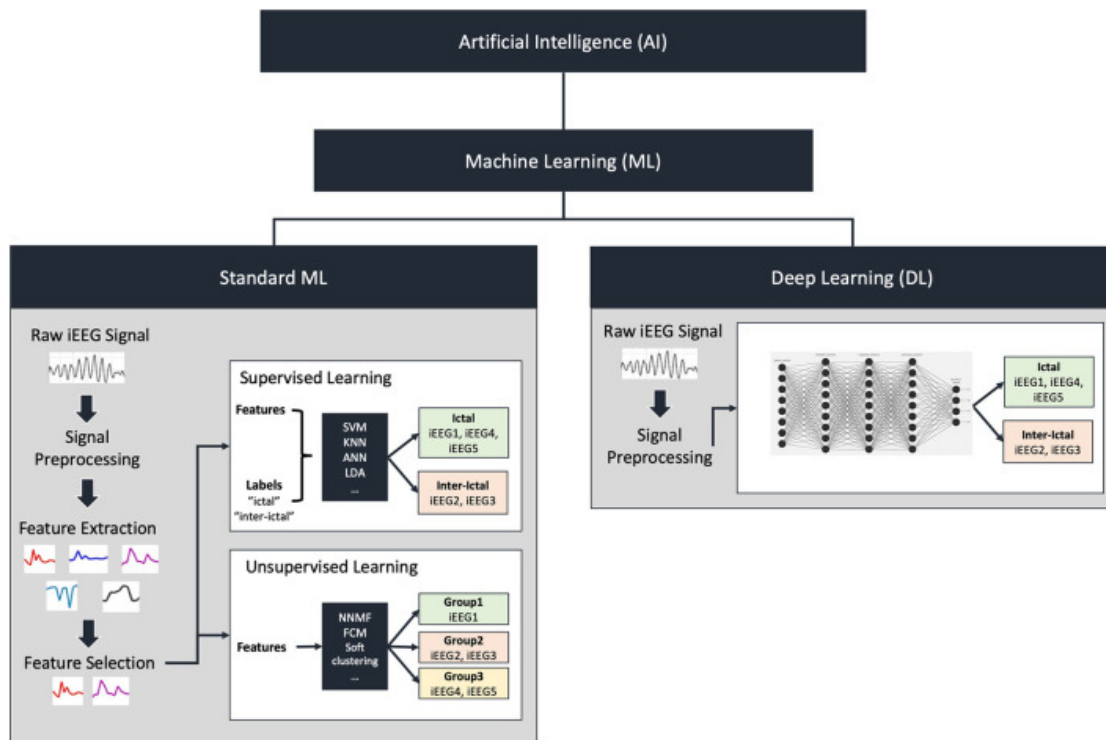
2.1.2. Podział algorytmów uczenia maszynowego

Najogólniejszego podziału algorytmów można dokonać, bazując na typie uczenia: nadzorowanym i nienadzorowanym. Charakterystyka obydwu typów algorytmów została przystępnie opisana w przeglądzie literatury dotyczącego dekodowanie wewnątrzczaszkowego EEG za pomocą uczenia maszynowego [31]:

„Uczenie nadzorowane polega na wykorzystaniu oznaczonych danych podczas szkolenia, dzięki czemu algorytm uczy się kojarzyć określone wzorce z wcześniej zdefiniowaną etykietą (na przykład dane związane z napadami lub stanami bez napadów). Uczenie bez nadzoru obejmuje nieoznakowane dane, w których algorytm otrzymuje duży zbiór danych i uczy się grupować

określone sygnały bez wcześniejszej wiedzy na temat klasyfikacji. [...]”

Kolejnym możliwym sposobem podziału algorytmów uczenia maszynowego na kategorie jest wyodrębnienie standardowych algorytmów od tych należących do nowo powstałej kategorii uczenia głębokiego. „Podstawową zaletą głębokiego uczenia w porównaniu do standardowego uczenia maszynowego jest to, że algorytmy te mogą uczyć się na podstawie surowych danych i automatycznie wyodrębniać znaczące informacje, omijając w ten sposób etapy selekcji cech wymagające dużego nakładu pracy człowieka. Należy jednak wziąć pod uwagę, że uczenie sieci głębokich może trwać znacznie dłużej i często wymaga większych próbek niż te powszechnie dostępne w populacjach neurochirurgicznych.” [31] Podział opisywany przez autorów wspomnianego przeglądu zaprezentowany został na rynku 2.3.



Rysunek 2.4: Podział algorytmów uczenia maszynowego

Źródło: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC9271576/>

2.1.3. Zastosowania uczenia maszynowego w analizie danych z badań iEEG

Zastosowania uczenia maszynowego w analizie badań iEEG można podzielić na 4 grupy w zależności od kierunku badań.

Napady epileptyczne

Pierwszą i najrozleglejszą kategorią prac są badania związane z napadami epilepsji. Nie jest to zaskakujące, biorąc pod uwagę fakt, że zdecydowana większość badań stereoEEG oraz

ECoG jest przeprowadzana na epileptykach. Badania w tej kategorii dotyczą następujących tematów: przewidywanie/wykrywanie napadów, przewidywanie wyników operacji, wykrywanie tkanek patologicznych, wykrywanie/klasyfikacja oscylacji o wysokiej częstotliwości (HFO), strefa początku napadu (SOZ)/lokalizacja ogniska padaczkowego, wykrywanie złych kanałów, wykrywanie skoków epileptycznych, wykrywanie tkanki nowotworowej. Zdecydowana większość badaczy stosuje tylko standardowe algorytmy uczenia maszynowego nadzorowanego w swoich badaniach, choć algorytmy należące do uczenia głębokiego także mają swój udział [31].

Motoryka

Do kolejnej kategorii należą badania z zakresu motoryki. Skupiają się na analizie aktywności mózgowej związanej z ruchem i kontrolą ruchu. Jednym z głównych obszarów badań jest zrozumienie, jak różne obszary mózgu współpracują podczas planowania i wykonania ruchu [32, 51]. Badania nad klasyfikacją ruchów korzystają z algorytmów do różnicowania zadań motorycznych, takich jak ruchy kończyn górnych i gesty ręki lub palców, na podstawie zapisów elektrofizjologicznych [28, 45]. Niektóre badania trenowały algorytmy do rozróżniania stanu spoczynku, intencji ruchu i wykonania ruchu, co pozwoliło na zrozumienie istotnych kroków przygotowania do ruchu [37]. Zastosowanie iEEG w połączeniu z uczeniem maszynowym może przyczynić się także do lepszego dostosowania neuroprotez do indywidualnego pacjenta. Aktualne protezy mięśniowe stosują podejście "jeden rozmiar pasuje do wszystkich", natomiast neuroprotezy oparte na uczeniu maszynowym mogłyby uczyć się od pacjenta i stawać się z czasem bardziej responsywne i precyzyjne [31].

Zadania poznawcze

Kluczową rolę uczenia maszynowego w tej dziedzinie stanowi potencjał do identyfikacji aktywności rozłożonej na różne zespoły neuronów związane z konkretnymi zadaniami [31].

W tej kategorii badań najczęściej badano ludzką pamięć. Badacze korzystający z tradycyjnych metod uczenia maszynowego uzyskali średnią skuteczność klasyfikacji w przypadku przypomnienia informacji w okolicach 60%. Klasyfikatory te wykazywały dużą zdolność do generalizacji. Ma to znaczne implikacje dla przyszłego rozwoju stymulacji zamkniętej pętli¹ zasilanej przez uczenie maszynowe, która może być w stanie przewidywać wydajność pamięci w szerokim zakresie kontekstów [31].

Badanie [1], w którym wykorzystano głębokie uczenie do klasyfikacji wydajności zadań pamięciowych i wykazano, że opracowany algorytm tylko nieznacznie przewyższa SVM². W związku z tym kwestią dyskusyjną pozostaje, czy niewielka poprawa wydajności przeważa nad brakiem transparentności głębokiego uczenia w porównaniu z SVM w tej dziedzinie.

Złożoność aktywności neuronalnej podczas zadań poznawczych odzwierciedla się w stosunkowo skromnych poprawach wydajności klasyfikacji algorytmów w porównaniu do przypadku

¹Stymulacja zamkniętej pętli (ang. closed-loop stimulation) to rodzaj terapii neuromodulacyjnej, w której urządzenie stymulujące mózg jest połączone z systemem detekcji sygnałów mózgowych. To połączenie tworzy "pętlę" informacyjną, gdzie urządzenie stymulujące jest w stanie odpowiedzieć na zmieniające się warunki w mózgu w czasie rzeczywistym.

²SVM (ang. Support Vector Machine) to popularny i prosty algorytm uczenia maszynowego używany do klasyfikacji i regresji.

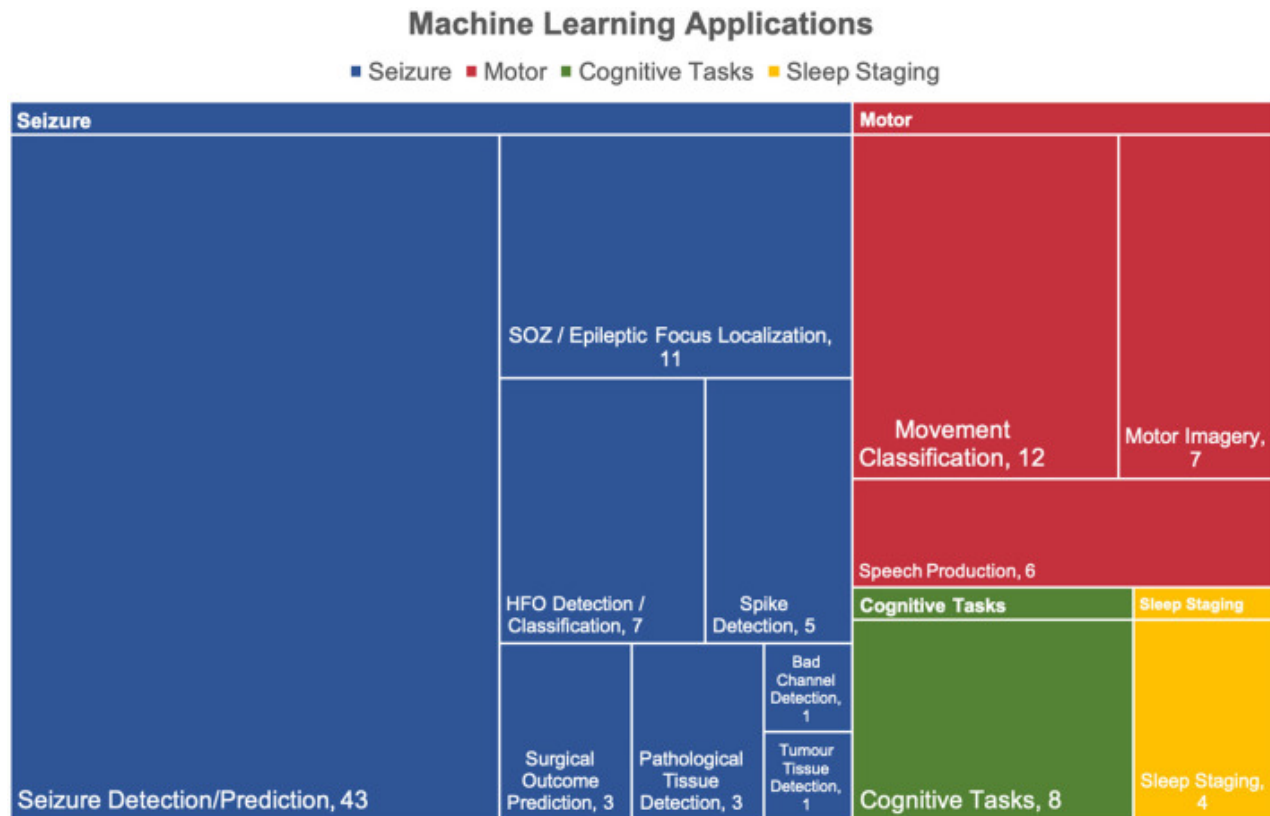
losowego. Mimo tych wyzwań modele te wykazały praktyczną użyteczność w stymulacji zamkniętej pętli dla pamięci [31].

Jednym z nowatorskich badań w tej dziedzinie była identyfikacja aktywnych elektrod podczas zadań z pamięcią werbalną [39]. Opracowano unikalną metodę uczenia nienadzorowanego, która znacznie przewyższała standardowe nadzorowane uczenie maszynowe, osiągając czułość na poziomie 97% i szczegółowość 92,9%.

W innej pracy SVM zostały wykorzystane do różnicowania, czy uczestnicy wykonują zadanie matematyczne, czy pamięciowe, osiągając średnią dokładność w okolicach 85% [40]. Kolejne badanie zastosowało wiele podejść z regresją logistyczną do różnicowania różnych typów bodźców słuchowych i wzrokowych, osiągając dokładność w zakresie od 80 do 95% [17].

Sen

Sygnatura fal mózgowych człowieka śpiącego znacząco różni się w poszczególnych fazach snu, co przekłada się na bardzo wysoką dokładność algorytmów uczenia maszynowego używanych w celu klasyfikacji owych stanów. Szersze wdrożenie tej technologii do użytku może pomóc odciążyć opiekę zdrowotną, np. przy badaniach snu u pacjentów [38]. Główną zaletą zastosowania uczenia maszynowego w tym kontekście jest szybkość klasyfikacji i dokładność wykrywania etapów snu. Według [20] podobne rozwiązania okażą się potrzebne w przyszłości: *„Zautomatyzowana klasyfikacja czuwania i SWS powinna okazać się przydatna w przyszłych wszczepialnych urządzeniach do padaczki o ograniczonej mocy obliczeniowej, pamięci i liczbie elektrod. Zastosowania obejmują ilościowe określanie wzorców snu pacjenta i zależne od stanu behawioralnego wykrywanie, przewidywanie i terapie stymulacją elektryczną.”*



Rysunek 2.5: Udział poszczególnych typów algorytmów uczenia maszynowego w analizie danych z badań iEEG.

Źródło: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC9271576/>

2.1.4. Ograniczenia uczenia maszynowego w analizie badań iEEG

W implementacji algorytmów uczenia maszynowego do analizy badań iEEG istnieje kilka przeszkód, o których należy wspomnieć.

Inwazyjny charakter samych badań wpływa na niską dostępność danych możliwych do wykorzystania w badaniach. Fakt, że są to dane medyczne wprowadza także konieczność anonimizacji, przed udostępnieniem ich w celach naukowych. Istnieje tylko kilka baz danych skupiających wyniki badań szerszej grupy pacjentów. Bazy te jednakże nie są optymalnie rozległe, zazwyczaj skupiając się na grupie kilkudziesięciu lub kilkuset pacjentów. Algorytmy uczenia maszynowego potrzebują natomiast bardzo dużej ilości danych do nauki w celu uzyskania pożądanego wyniku. Mała liczba pacjentów ma także wpływ na generalizację algorytmów, która w tym wypadku może nie być wystarczająca, powodując stroniczość algorytmów.

Badania iEEG wykonywane są w zdecydowanej większości na osobach chorych na epilepsję, co przy badaniach skierowanych na zrozumienie działania mózgu zdrowych wymaga identyfikacji i pominięcia aktywności epileptycznej wśród pacjentów.

Kolejnym problemem jest fakt, że dane iEEG mogą się znacznie różnić między różnymi pacjentami, co może utrudniać uczenie maszynowe. Modele mogą wymagać dostosowania

do każdego pacjenta indywidualnie, co jest czasochłonne. Wielowymiarowość i złożoność danych iEEG utrudnia proces uczenia. Konieczne jest przetworzenie wstępne danych, mimo to algorytmy mogą wymagać dużo czasu i mocy obliczeniowej do przetwarzania tych danych. Zazwyczaj dane te są także niezbalansowane, co dodatkowo utrudnia proces uczenia algorytmów i jest kolejnym aspektem, o który trzeba zadbać podczas implementacji. Niestety brak standardów we wstępnym przetwarzaniu danych przed wprowadzeniem do modelu uczenia maszynowego może prowadzić do niekonsekwencji i błędów.

Algorytmy klasyfikowane do głębokiego uczenia zazwyczaj osiągają lepsze wyniki w różnych aspektach analizy danych iEEG, niestety często brakuje im wyjaśnialności, co oznacza, że trudno jest zrozumieć, jak dokładnie model podejmuje swoje decyzje. To może być problemem w kontekście medycznym, gdzie zrozumienie procesu decyzyjnego może być kluczowe. Często dyskwalifikuje to zastosowanie bardziej wyrafinowanych algorytmów.

2.1.5. Wstępne przetwarzanie danych

Wstępne przetwarzanie danych w przypadku analizy danych iEEG jest krokiem kluczowym. Kilka istotnych kroków jest powszechnie stosowanych przed rozpoczęciem faktycznej analizy, a błąd popełniony w jednym z nich może mocno zdegradować wynik końcowy: połączenie plików danych, redukcja częstotliwości próbkowania sygnałów, usuwanie artefaktów (do których należy m.in. aktywność epileptyczna), segmentacja, normalizacja, dobór cech, redukcja wymiarowości, balans równowagi klasowej.

Łączenie plików danych

W przypadku badań analizujących zmiany w czasie, jak badania snu czy napadów epileptycznych, monitoring pacjentów za pomocą iEEG często trwa kilka lub nawet kilkanaście dni. Dane uzyskane w ten sposób często zapisywane są w wielu plikach. Ponadto, podczas monitoringu pacjenci mogą być poddani dodatkowym testom ukierunkowanym w stronę badania konkretnego zagadnienia naukowego, np. enkodowaniu pamięci [1]. W tym wypadku testy te zwykle podzielone są na sesje, pomiędzy którymi pacjent może odpocząć, lub po prostu odbywają się w kolejnych dniach. Każda z sesji zapisywana jest wtedy w osobnym pliku w celu łatwiejszej nawigacji po nagraniach. W przypadku analizy przeprowadzanej przez algorytmy uczenia maszynowego pliki te łączy się w celu zwiększenia rozmiaru próbki i mocy statystycznej analizy.

Redukcja częstotliwości próbkowania sygnałów

Dla większości sygnałów iEEG moc sygnału oscyluje w paśmie niskich częstotliwości. Redukcja częstotliwości próbkowania tych sygnałów pozwala skoncentrować się na tych niższych częstotliwościach, zmniejszając wpływ szumów o wyższej częstotliwości. Dodatkową zaletą plików ze zredukowaną częstotliwością próbkowania jest mniejsze zapotrzebowanie na moc obliczeniową komputera podczas analizy. Redukcja częstotliwości próbkowania przełoży się na przyspieszenie, a przy tym ułatwienie wszystkich kolejnych kroków analizy danych.

Segmentacja

Wiele badań iEEG skupia się na konkretnych zdarzeniach, takich jak napady padaczkowe, fale mózgowe w trakcie snu lub enkodowaniu pamięci. Segmentacja pozwala na wyizolowanie tych zdarzeń i skupienie się na nich w analizie. Długość segmentów ustalana zależna jest od rodzaju przeprowadzanych badań. Segmenty mają długość od dziesiątych części sekundy do kilkudziesięciu sekund. Często techniką jest podzielenie sygnału w sposób, w którym segmenty po części nakładają się na siebie. Pozwala to unikać rozbicia ważnych dla badań zdarzeń na kolejne segmenty.

Normalizacja

Pierwszym typem normalizacji w kontekście badań iEEG jest normalizacja przestrzenna. Jej wynikiem jest tabela ze współrzędnymi $[x\ y\ z]$ w znormalizowanej przestrzeni (np. MNI) dla każdej elektrody. MNI (ang. Montreal Neurological Institute) odnosi się do standardowego systemu odniesienia przestrzennego dla obrazowania mózgu. W tym systemie, obrazy mózgu różnych osób są transformowane do wspólnego przestrzennego układu odniesienia. Dzięki temu można dokładniej powiązać zarejestrowaną aktywność elektryczną z konkretnymi strukturami mózgu.

Kolejnym typem normalizacji jest normalizacja mocy sygnału w zakresie każdego z kanałów. SNR (ang. signal-to-noise-ratio) może mocno różnić się nawet w obrębie jednej elektrody. Z tego powodu normalizacja surowego sygnału do linii bazowej jest bardzo ważne. Linia bazowa jest powszechnie definiowana jako średnia moc sygnału.

Dobór cech

W badaniach skupiających się na wykrywaniu i przewidywaniu napadów stosuje się reprezentacje czasowo-częstotliwościowe surowych sygnałów EEG. Wykorzystuje się do tego różne metody transformacji sygnałów, jak transformacje Fouriera czy falkowa. Amplitudy różnych zakresów częstotliwości w danym segmencie sygnału są zwykle wykorzystywane do obliczania cech statystycznych.

Cechy dobierane do badań nad motoryką i zdolności poznawczych skupiają się na falach o niższej częstotliwości, takich jak theta [25], alfa i pasma beta. Cechy te zazwyczaj koncentrują się na amplitudzie, mocy widmowej i jej transformacjach. Powszechnie stosowana jest znormalizowana moc logarytmiczno-spektralna uzyskana z transformaty falkowej Morleta [1].

Redukcja wymiarowości

W celu zredukowania liczby wymiarów danych najczęściej stosuje się popularny algorytm PCA (ang. principal component analysis) lub tSNE (ang. t-distributed stochastic neighbor embedding).

Balansowanie równowagi klasowej

Często zdarza się, że liczebność poszczególnych klas zdarzeń jest niebalansowana, np. klasy słów przywołanych i nieprzywołanych podczas badań pamięci. Może to mieć negatywny

wpływ na wydajność klasyfikatorów. W celu zbalansowania liczebności klas uznana strategią jest zastosowanie SMOTE (ang. Synthetic Minority Oversampling Technique).

2.1.6. Lokalizacja aktywności epileptycznej w danych iEEG

Problem lokalizacji aktywności epileptycznej w danych iEEG, który dotyczy także tej pracy, jest dobrze znany w środowisku naukowym. Wynika to z faktu, że znaczna część badań iEEG jest wykonywana na pacjentach chorych na padaczkę. Lekarze i badacze zajmujący się padaczką muszą często przeglądać duże ilości ciągłych danych EEG, aby zidentyfikować napady, które u niektórych pacjentów mogą być dość subtelne. Zautomatyzowane algorytmy wykrywania napadów znacznie ułatwiły opiekę kliniczną i badania podstawowe. Do realizacji tego zadania przetestowano szeroki zakres algorytmów uczenia maszynowego, co odzwierciedla się w dużej liczbie artykułów naukowych dotyczących tego tematu.

Standardowym podejściem do problemu jest zastosowanie klasycznych algorytmów uczenia maszynowego. Po wyodrębnieniu cech z sygnałów iEEG kolejnym krokiem jest klasyfikacja zdarzeń normalnych i epileptycznych przy użyciu klasyfikatora, takiego jak k-najbliższych sąsiadów (kNN), liniowej analizy dyskryminacyjnej (LDA), maszyny wektorów nośnych (SVM). W ostatnich latach popularnym rozwiązaniem tego problemu staje się także zastosowanie głębokich sieci neuronowych [26, 41].

2.2. Pupilometria

Pupilometria jest stosowana w medycynie od ponad 100 lat. W ostatnich latach badanie to zyskało ponowne zainteresowanie ze strony lekarzy i naukowców, z uwagi na wzrost możliwości pomiarowych sprzętu niezbędnego do zautomatyzowanej pupilometrii oraz nowe zastosowania m.in. jako ogólnie dostępny biomarker sprawności ludzkiej pamięci i stanów poznawczych w ogóle. W opublikowanych pracach naukowych dogłębnie opisano aspekt obróbki oraz analizy danych pozyskanych podczas tego typu badań.

2.2.1. Charakterystyka badania

Badania pupilometryczne zwykle wykorzystują specjalistyczne kamery do śledzenia oka, które są w stanie precyzyjnie mierzyć zmiany rozmiaru źrenicy w czasie i w odpowiedzi na prezentowane bodźce. W trakcie badania kamera pupilometru nagrywa obraz oka pacjenta, skupiając się na źrenicy. Zmiany w rozmiarze źrenicy mogą następnie być powiązane z różnymi stanami fizjologicznymi lub emocjonalnymi. Rozmiar źrenicy to sygnał ciągły: szereg czasowy określający jak rozmiar źrenicy zmienia się w czasie. W tym kontekście dane dotyczące z pupilometrii są podobne do danych z elektroencefalografii.

2.2.2. Wstępne przetwarzanie danych

Proces przetwarzania wstępnego dla danych pupilometrii oparty na aktualnych standardach wygląda w następujący sposób:

- usuwanie zarejestrowanych mrugnięć oka (ang. debinking),

- odrzucanie artefaktów (spowodowanych warunkami klinicznymi, takimi jak ruch wynikający z dyskomfortu lub bólu),
- wygładzanie — stosowane w celu zredukowania szumów i fluktuacji w zestawie danych, aby ułatwić identyfikację głównych trendów lub wzorców. Najczęściej stosuje się w tym celu średnią ruchomą (ang. moving window average),
- interpolacja — po wycięciu z danych artefaktów i mrugnięć oczu, powstałe nieciągłości w szeregach czasowych interpoluje się, korzystając z próbek poprzedzających wycięte zdarzenie. Dwie powszechnie stosowane metody interpolacji danych z pupilometrii to interpolacja liniowa oraz sześciennie-liniowa.
- korekcja linii bazowej — pozwala to na standardowe porównanie danych z badań pomiędzy różnymi pacjentami.

Aby zwiększyć przejrzystość tego procesu, zalecana jest wizualizacja danych zarówno przed jak i po etapie przetwarzania wstępnego, w celu przeprowadzenia dodatkowej oceny wizualnej procesu.

2.2.3. Zastosowanie uczenia maszynowego w analizie danych z pupilometrii

Dzięki swojej zdolności do identyfikacji wzorców w danych uczenie maszynowe znajduje szereg zastosowań w analizie danych z pupilometrii.

Rozmiar źrenicy zmienia się w odpowiedzi na różne emocje, takie jak radość, smutek, strach lub zaskoczenie. Algorytmy uczenia maszynowego mogą posłużyć do klasyfikacji stanów emocjonalnych badanych osób na podstawie danych z pupilometrii [22]. Na rozmiar źrenicy może mieć także zmęczenie lub stres. Zastosowanie tej analizy w motoryzacji do monitorowania kierowców pod kątem oznak zmęczenia, mogłoby pomóc w zapobieganiu wypadkom [2].

Kolejna z możliwych implementacji uczenia maszynowego na danych z pupilometrii dotyczy monitorowania chorób neurologicznych. Choroba Parkinsona czy stwardnienie rozsiane, może wpływać na rozmiar źrenicy. Badania z powodzeniem zaimplementowały nowoczesne algorytmy w próbie wykrywania takich chorób na wczesnym etapie, a także w monitorowaniu postępu choroby i reakcji na leczenie [6].

Wreszcie pupilometria może przysłużyć się w badaniach nad zdolnościami poznawczymi. Niedawne badania wskazują na możliwość wykorzystania jej jako biomarkera przy zadaniach związanych z enkodowaniem pamięci [21].

2.3. Kodowanie pamięci

Kodowanie pamięci w ludzkim mózgu cały czas jest tematem niszowym i słabo zbadanym w środowisku naukowym. Po części wynika to z ograniczeń i trudności związanych z badaniem ludzkiego mózgu – zarówno etycznych jak i technologicznych. Ilość prac dotyczących tego zagadnienia jest stosunkowo mała. Badania typowe dla prac podejmujących ten temat pochodzą z obszaru neuroobrazowania (np. elektroencefalografia wewnątrzczaszkowa). Najnowsze badania proponują użycie danych pochodzących z pupilometrii jako potencjalnego

biomarkeru w badaniach przetwarzania pamięci [21]. Dane służące badaniom enkodowania pamięci rejestrowane są podczas specjalnie do tego stworzonych testów behawioralnych [8, 23].

2.3.1. Korzyści z badań

Postęp badań nad kodowaniem pamięci może przynieść korzyści w kilku dziedzinach. Według autorów [21]: „Wiedza pochodząca z połączonych zapisów aktywności mózgu i reakcji oczu może być bezpośrednio zaimplementowana w powstających technologiach neuromodulacji.” Odkrycia dokonane w tej domenie mogą pomóc w projektowaniu urządzeń interfejsu mózg — maszyna, które będą wpływać na przetwarzanie pamięci. Wspomniane badania będą także mogły posłużyć do przewidywania utrat pamięci u pacjentów po operacji płata skroniowego [1]. Każde z badań nad kodowaniem pamięci pozwala naukowcom lepiej zrozumieć, jak informacje są zapisywane, przetwarzane i odzyskiwane w mózgu. Dzięki temu możliwe staje się zgłębienie podstawowych mechanizmów pamięci i rozwój kognitywistyki. Być może badanie te one wskazówek dotyczących leczenia i terapii zaburzeń pamięciowych, takich jak choroba Alzheimera czy amnezja.

2.3.2. Zastosowanie sEEG do badań nad kodowaniem pamięci

sEEG pełni ważną rolę w badaniach nad kognitywistyką. Zdolność do obserwowania sygnałów neurofizjologicznych z wysoką rozdzielczością czasową i przestrzenną między precyzyjnie zlokalizowanymi populacjami neuronów w różnych regionach mózgu niesie ze sobą możliwość lepszego zrozumienia jego działania. Dane zabrane podczas badań mogą posłużyć do stworzenia algorytmów będących w stanie automatycznie rozpoznać skuteczne zaenkodowanie informacji w pamięci. Wypróbowano różne metody z zakresu uczenia maszynowego, zarówno te tradycyjne jak i z dziedziny uczenia głębokiego (LR, SVM, RNN) [1]. Autorzy wspomnianej pracy naukowej wykazują, że rekurencyjne sieci neuronowe (RNN) lepiej radzą sobie w klasyfikacji w zdecydowanej większości przypadków. Zwracają oni także uwagę na zaletę korzystania z algorytmów służącym redukcji wymiarowości danych — widoczną poprawę wydajności modeli.

2.3.3. Zastosowanie pupilometrii do badań nad kodowaniem pamięci

Sygnał rejestrowany podczas śledzenia zmian w obszarze źrenicy zawiera informacje o stanach mózgu i procesach poznawczych leżących u podstaw kodowania, przechowywania i przywoływania pamięci. Zaobserwowano duże zmiany w szerokości źrenicy u pacjentów w momentach, gdy badani aktywnie przypominali sobie słowa. W związku z tym rozmiar źrenicy odzwierciedlał proces poznawczy związany z aktywnym przywoływaniem zakodowanej pamięci [21]. Jednym ze sposobów analizy tego rodzaju danych jest zastosowanie uczenia maszynowego [50].

Nowe badania dostarczyły także dowodów na to, że procesy kodowania pamięci jest wrażliwy i osłabiony u przedobjawowych osobników na chorobę Alzheimera co sugeruje możliwe wyjaśnienie subtelnych zaburzeń wizualnej pamięci krótkotrwałej (VSTM) obserwowanych w przedklinicznych stadiach Alzheimera. W badaniach tych kluczowym odkryciem było powiązanie ruchów gałek ocznych podczas enkodowania pamięci — indeksowanymi pośrednio

przez całkowity czas spędzony na utrwalaniu bodźca, a wydajnością VSTM, różniąca się między osobami chorymi na Alzheimera a grupą kontrolną [33].

3. Dane i ich wstępne przygotowanie

Dane wykorzystane do badań w tej pracy zostały zebrane od pacjentów przez organizację Mayo Clinic za ich w pełni świadomą zgodą. Zbiór danych zawiera sygnały sEEG zarejestrowane u 10 pacjentów z padaczką lekooporną. Pacjentów poddano inwazyjnemu monitorowaniu w celu lokalizacji napadów podczas wykonywania czterech zadań pamięciowych. [8] Podczas wykonywania tych zadań, u pacjentów monitorowano dodatkowo wielkość źrenicy oraz nagrywano wypowiedziane przez nich słowa. Sygnały sEEG i pupilometryczne zostały zapisane w strukturze danych BIDS. Opisywany zbiór danych waży około 500GB i został pobrany z portalu EBRAINS.EU. Autorzy zbioru danych opisali zagadnienia z nim związane (tj. metody rejestrowania danych, uwagi dotyczące użytkowania) w artykule naukowym [8].

3.1. Rejestrowanie danych

Szczegóły dotyczące rejestrowania danych zostały dobrze opisane przez autorów zbioru. Dzięki uporządkowaniu plików w strukturze BIDS (ang. Brain Imaging Data Structure), nawigacja pomiędzy poszczególnymi badaniami i sesjami jest intuicyjna. Udostępnione dane przeszły także walidację techniczną wykonaną przez zespół ekspertów [8].

3.1.1. iEEG

Sygnały zostały zebrane za pomocą standardowych klinicznych elektrod penetrujących wszczepionych w miąższ mózgu, zarówno istotę szarą, jak i istotę białą. Elektrody rejestrowały sygnały z częstotliwością 32 kHz. Każdemu z pacjentów wczepiono około 10 elektrod, gdzie na każdą składało się do kilkunastu kontaktów mierzących aktywność elektryczną mózgu. Kontakty oddalone są od siebie o 5-10 mm. W przypadku każdego pacjenta liczba i rozmieszczenie elektrod zostały określone przez zespół kliniczny w celu zlokalizowania epileptogennych obszarów mózgu. Pacjentom wszczepiono elektrody głębokościowe przy użyciu procedury stereo-EEG, która obejmowała stereotaktyczne planowanie trajektorii implantacji w trójwymiarowej przestrzeni anatomicznej mózgu. Badaniem objęto następujące struktury mózgu: „(...) korę oczodołowo-czołową, przedni zakręt obręczy, wyspę, ciało migdałowate, zakręt nadskrzyżowaniowy i kątowy, górny płat ciemieniowy, meżalną i boczną korę przedczołową oraz brzuszno-boczną korę przedczołową, wraz z pięcioma podstawowymi obszarami wspólnymi dla wszystkich osób: hipokampem, górnym płatem ciemieniowym (SPL), tylnym zakrętem obręczy, boczną korą skroniową (w płaszczyźnie wieńcowej tuż za bruzdą ciała migdałowatego i hipokampa) oraz dolnym płatem ciemieniowym (zakręt kątowy lub nadskroniowy). Ten podstawowy zestaw pięciu regionów mózgu został zachowany u wszystkich badanych, ponieważ obejmuje obszary skroniowe i pozaskroniowe rutynowo pobierane w celu scharakteryzowania padaczki płata skroniowego.” [8].

3.1.2. Pupilometria

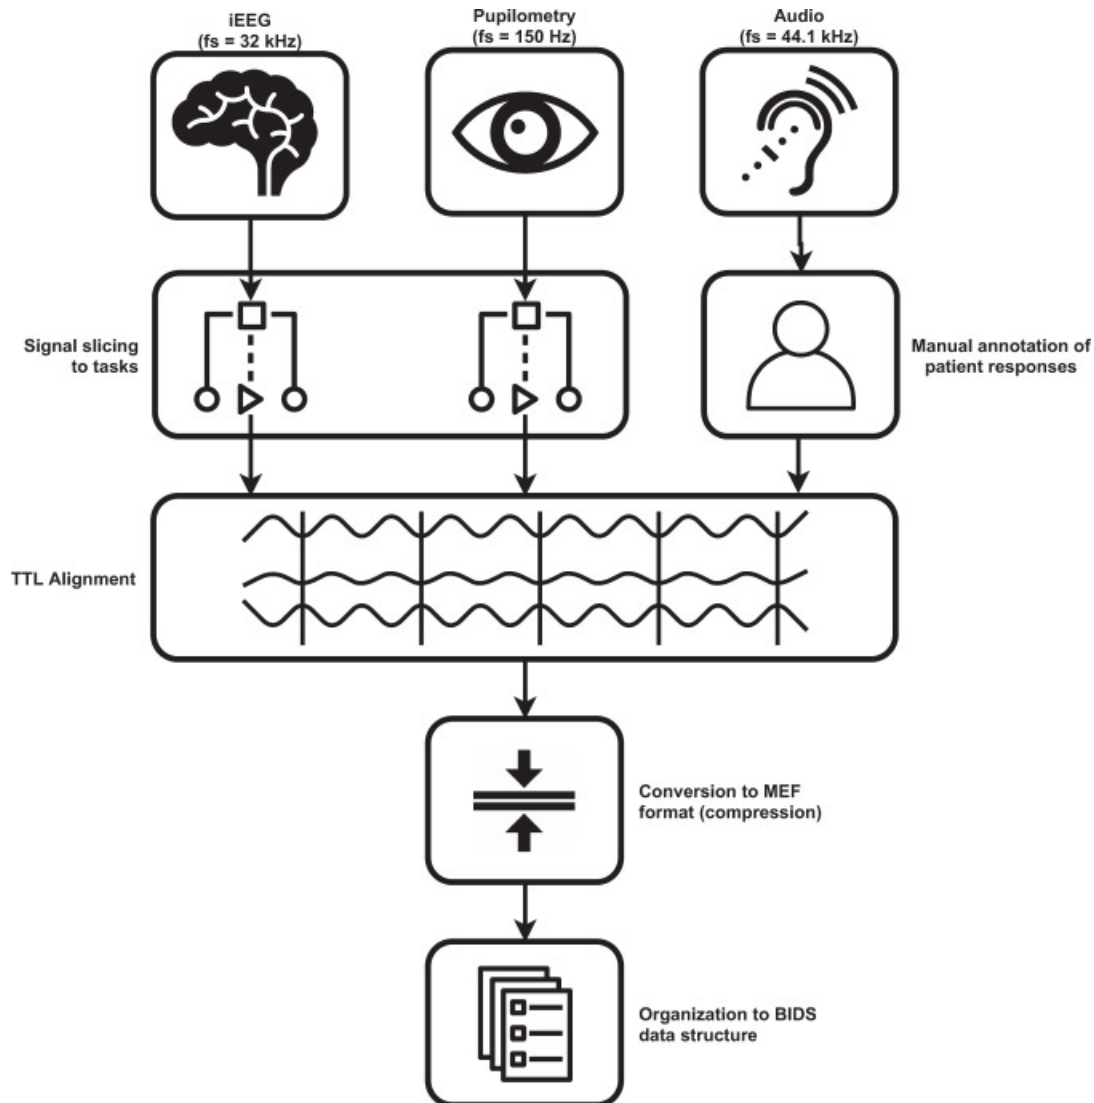
Rejestracja pozycji spojrzenia i rozmiaru źrenicy była realizowana za pomocą specjalnie zaprojektowanego oprogramowania opartego na systemie i4tracking (Medicton group Inc., Praga, Czechy), zaprojektowanym do zastosowań klinicznych. Rejestrację przeprowadzano na laptopie podłączonym do monitora o przekątnej 24 cali i rozdzielczości 1680×1050 pikseli, gdzie pozycja spojrzenia była śledzona za pomocą kamery o wysokiej rozdzielczości (2048×1088 pikseli) i szybkości (do 150Hz), umieszczonej tuż pod ekranem, na wysokości oczu pacjenta. Bodźce były wyświetlane na ekranie z użyciem czcionki o rozmiarze 100 punktów i były obserwowane z odległości około 60 cm. Pozycję i rozmiar źrenicy rejestrowała kamera, co odpowiadało około 0,1 mm na piksel w obrazie oka. [8]

Przed rozpoczęciem zadań pamięciowych kalibrowano śledzenie wzroku dla każdego pacjenta. W procedurze kalibracji pacjenci byli proszeni o skupienie spojrzenia na dziewięciu punktach prezentowanych kolejno w określonych pozycjach na przekątnych i środkach krawędzi bocznych ekranu wyświetlacza. Kalibrację powtarzano przed rozpoczęciem każdego nowego zadania w sesji, aby zapewnić dokładną ocenę rozmiaru źrenicy.

Pomimo tych starań, jakość śledzenia oka była niższa pod koniec każdego zadania z powodu niewielkich zmian w skupieniu spojrzenia związanych ze zmianami pozycji głowy. Wszystkie bodźce były prezentowane na ekranie w kolorze jasnoszarym na tle w tym samym kolorze, aby zminimalizować reakcje źrenicy na zmieniające się oświetlenie i kontrast. Testy przeprowadzano w pomieszczeniu o stałych warunkach niskiego oświetlenia.

3.1.3. Format danych

Dane każdego z rodzajów badań zostały pocięte na segmenty, a następnie wyrównane w czasie w oparciu o impulsy TTL (ang. Transistor-Transistor-Logic), używane do precyzyjnego oznaczania czasu określonych zdarzeń. Zdarzenia te zostały ręcznie adnotowane przez specjalistów w ramach zadań pamięciowych. Sygnały zapisano w formacie MEF (ang. Multiscale Electrophysiology Format) i zorganizowano w strukturze danych BIDS w celu dalszego przeglądania i automatycznego przetwarzania. Opisany proces przedstawiony jest na rysunku 3.1. Wszystkie dane zostały zanonimizowane podczas tego procesu poprzez pominięcie wszelkich informacji, które mogłyby prowadzić do identyfikacji pacjenta, takich jak imię i nazwisko oraz data urodzenia.



Rysunek 3.1: Schemat konwersji danych do ostatecznej struktury.

Źródło: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC8758703/>

3.1.4. Rekordy danych

Dane obejmują nagrania od 10 pacjentów, którzy w czasie badań przeprowadzili 65 zadań. Podsumowanie wykonanych zadań z nagraniami z określonej liczby wszczepionych kontaktów przedstawiono w tabeli 3.1. Poszczególne realizacje identycznego zadania przez tego samego pacjenta były przeprowadzane w odstępach czasu wynoszących od 24 do 72 godzin.

Nieprzetworzone dane z sEEG, nagrań audio oraz z pupilometrii zostały zapisane w formacie MEF3 ze względu na jego zdolność do obsługi kompresji danych, zmiennej częstotliwości próbkowania sygnałów i wszelkich nieciągłości sygnału. Interfejsy API MEF dla Pythona są publicznie dostępne. Plikom, w których zapisano sygnał z badań, towarzyszą czytelne dla człowieka metadane. *„Metadane są przechowywane w plikach .tsv i .json i zawierają informacje o lokalizacji anatomicznej zaimplantowanych elektrod (struktura anatomiczna i*

Tabela 3.1: Przegląd całkowitej liczby zadań i zapisów z elektrod u poszczególnych pacjentów.

Subject	AP runs	FR runs	PAL runs	SP runs	N contacts	Vision aids	Interpupillart distance[mm]	Psychiatry
sub-003	1	2	0	1	128	No	75	depression, ADHD
sub-004	2	2	2	2	128	No	65	No
sub-005	4	4	4	4	128	No	65	No
sub-006	0	1	1	0	128	No	64	No
sub-007	1	1	1	1	128	No	68	No
sub-008	0	0	0	1	128	No	65	No
sub-009	0	2	2	2	70	No	61	No
sub-010	0	1	0	1	118	Glasses	60	No
sub-011	2	2	2	2	128	Glasses	65	depression
sub-012	3	4	4	3	128	Contact lenses	58	No
Total N	13	19	16	17	1212			

Źródło: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC8758703/>

współrzędne w przestrzeni koordynat skanera), częstotliwości próbkowania kanałów, jakości kanałów i zdarzeniach behawioralnych (np. prezentacje słów, przypomniane słowa, sakady). Struktura danych jest zgodna ze standardem BIDS w wersji 1.2.1, a poziomy folderów są uporządkowane w kolejności pacjent-sesja-iEEG-zadanie-przebieg.” [8].

Zbiór danych jest dostępny zgodnie z warunkami umowy EBRAINS dotyczącej wykorzystania danych ludzkich za pośrednictwem EBRAINS Knowledge Graph.

3.1.5. Walidacja techniczna

Po zarejestrowaniu sygnałów zebrane dane zweryfikowano w celu sprawdzenia, czy sygnały nie zawierają błędnych danych pochodzących z kontaktów, które były uszkodzone lub zaimplantowane poza tkanką mózgową. Informacje na temat jakości sygnałów zapisano w plikach BIDS_channels.tsv dla każdego pacjenta i zadania.

Odpowiedzi werbalne pacjentów podczas wykonywania zadań pamięciowych zostały ręcznie oznaczone w sygnałach sEEG oraz z pupilometrii przy użyciu nagrań głosowych. Adnotacje wskazują moment rozpoczęcia werbalizacji słowa. Dane z badań iEEG oraz z pupilometrii zostały sprawdzone pod kątem właściwej wzajemnej synchronizacji.

3.1.6. Ograniczenia zbioru danych

Zbiór danych zawiera stosunkowo niewielką liczbę nagrań, co może mieć istotny wpływ na wydajność algorytmów uczenia maszynowego. Informacje o współrzędnych poszczególnych elektrod oraz kontaktów, przechowywane w plikach BIDS_electrodes.tsv są dostarczane w przestrzeni skanera MRI, a nie konkretnego, uniwersalnego układu współrzędnych i dlatego nie mają zastosowania u różnych pacjentów. Zbiór danych nie zawiera wspomnianych wyżej skanów MRI ze względu na ochronę prywatności pacjentów.

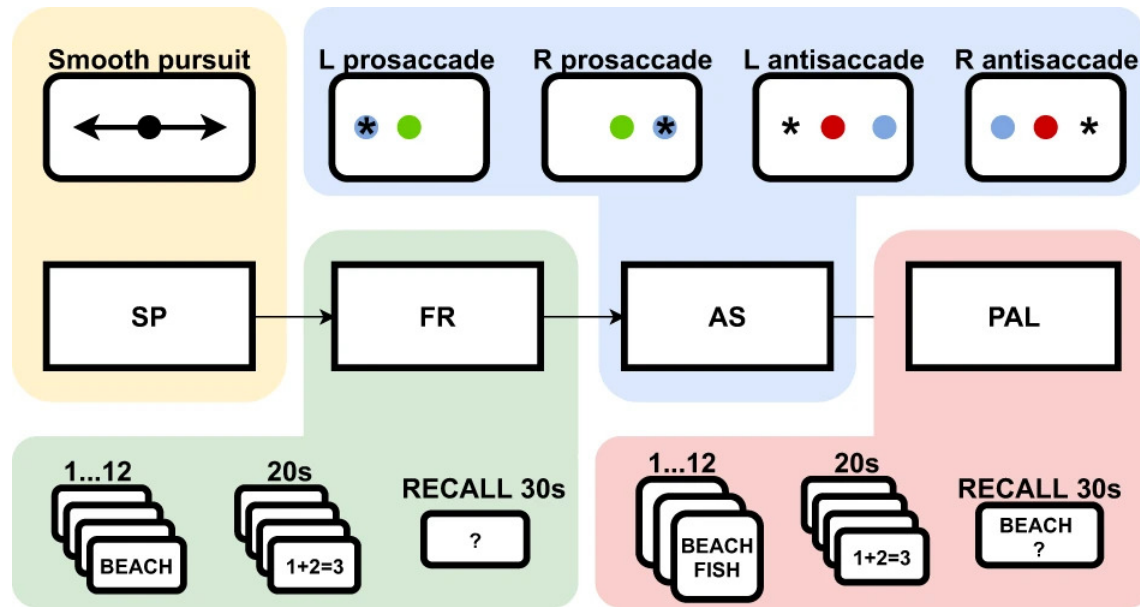
3.1.7. Uwagi dotyczące użytkowania

Autorzy zbioru danych zalecają korzystanie z bibliotek kompatybilnych ze strukturą BIDS, takich jak pybids [47], w celu łatwego manipulowania samym zbiorem. Autorzy załączyli także notatnik jupyter z przykładowym kodem do odczytu danych w języku programowania Python.

Skatalogowane sygnały nie zostały wstępnie przetworzone, aby zapewnić dane w surowej postaci i umożliwić użytkownikom wykonanie własnego przetwarzania wstępnego. Autorzy dostarczyli jednakże kod w języku Python pozwalający na wykrycie aktywności epileptycznej. Sygnały pupillometryczne zawierają artefakty mrugania i artefakty spowodowane ustawieniami klinicznymi, takimi jak ruch spowodowany dyskomfortem lub bólem. Sposób eliminacji wymienionych artefaktów został opisany w jednej z prac naukowych [27]. Autorzy zalecają skorzystanie z programu PySigView [7] w celu przeglądania danych zapisanych w MEF3. Nagrania iEEG ograniczono do 128 kanałów, mimo że liczba wszczepionych kontaktów była wyższa.

3.2. Zadania pamięciowe

Po implantacji elektrod każdy pacjent brał udział w serii czterech zadań poznawczych, badających pamięć werbalną i ruchy oczu przy jednoczesnym śledzeniu rozmiaru źrenicy i pozycji spojrzenia na ekranie zadania. Wszystkie zadania były wykonywane przez pacjentów z wszczepionymi elektrodami, wygodnie odpoczywających na łóżku szpitalnym podczas jednej sesji eksperymentalnej dziennie. Zadania te były oznaczane automatycznie w nagraniach sEEG, natomiast odpowiedzi behawioralne (wokalizacje zapamiętanych słów i ruchy oczu na ekranie) były anotowane po eksperymencie. Pacjenci zostali poinstruowani, aby leżeć nieruchomo na łóżku, nie ruszać się i skupić wzrok na środku ekranu. Ogólny przebieg jednej sesji zadań jest przedstawiony na rysunku 3.2



Rysunek 3.2: Przegląd zestawu zadań wykonywanych przez pacjentów. SP – smooth pursuit, FR – free recall, AS – anti-pro saccade, PAL - paired-associate learning.

Źródło: <https://www.nature.com/articles/s41597-021-01099-z/figures/1>

Procedura zaczynała się od zadania Smooth Pursuit (SP), w którym pacjenci śledzili poziomo poruszający się punkt na środku ekranu ze stałym, wolnym przyspieszeniem. „SP kontroluje nie tylko wszelkie deficyty okulomotoryczne i/lub sensoryczne, ale także sensoryczno-motoryczną (niewerbalną) pamięć roboczą ze znanymi neurofizjologicznymi substratami upośledzonymi w określonych zaburzeniach mózgu.” [8].

Następnie odbywało się główne zadanie pamięciowe, polegające na swobodnym przypominaniu (FR) list słów, w którym pacjenci byli proszeni o zapamiętanie 12 słów prezentowanych pojedynczo na ekranie komputera, a następnie o ich przypomnienie w dowolnej kolejności po krótkim zadaniu rozpraszającym polegającym na prostych równaniach algebraicznych.

Trzecie zadanie dotyczyło ruchu oczu i było wykonywane w celu zredukowania interferencji bodźców słownych przed końcowym zadaniem. Zadanie to jest klasycznym wzorcem dla ruchów oka sakkadycznych i anty-sakkadycznych (AS), skierowanych w stronę kolorowego punktu, który zmienia pozycję na prawo lub na lewo od centrum ekranu.

Sesję zadań kończyła inna wersja zadania pamięciowego - PAL (paired-associate learning). W przeciwieństwie do listy słów w zadaniu FR, PAL wykorzystywało 6 par słów wyświetlanych jeden po drugim do późniejszego przypomnienia z pomocą podpowiedzi. Analogicznie zastosowano jednak dystraktor w postaci prostego równania algebraicznego przed częścią przypominania. Celem tego zadania było zbadanie nauki skojarzeń par słów.

Podsumowując, każda sesja zadań składała się z zestawu czterech zadań wykonywanych w następującej kolejności: SP, FR, AS, PAL. Celem było zarejestrowanie wszystkich zadań podczas jednej sesji, ale nie zawsze było to możliwe. Sesje zadań odbywały się co najmniej raz dziennie, z przynajmniej jednym ukończonym zadaniem.


3.3. Wstępne przygotowanie danych

Zarówno dane zebrane podczas sEEG jak i pupilometrii wymagają obszernej obróbki przed wprowadzeniem ich do algorytmów uczenia maszynowego.

3.3.1. Identyfikacja miarodajnych kanałów

Z czterech typów zadań wykonywanych przez pacjentów wybrano tylko jedno - FR (ang. free recall). Zadanie to zostało zaprojektowane specjalnie w celu badania ludzkiej pamięci. Ograniczyło to zakres grupy badawczej do 9 pacjentów, jako że 'sub-008' nie wykonał ani jednej sesji zadania FR. Po dalszej analizie zdecydowano się odrzucić dane zebrane od kolejnych 2 pacjentów z następujących powodów:

- sub-006: niska jakość danych, duża liczba artefaktów, tylko jedna, niedokończona sesja FR o bardzo małej liczbie poprawnych odpowiedzi (zaledwie 12/143). W drugiej połowie sesji pacjent nie był w stanie przypomnieć sobie żadnego słowa. Było to prawdopodobnie spowodowane uwarunkowaniami klinicznymi np. odczuwanym przez pacjenta bólem. Fragment sygnału zarejestrowanego u tego pacjenta znajduje się na rysunku 3.3.
- sub-010: niekompletność sygnałów, duża liczba artefaktów, ogólna niska jakość danych.



Rysunek 3.3: Odczyt średnicy źrenicy oka niskiej jakości, zawierający dużą ilość artefaktów. Zrzut ekranu został zrobiony w programie PySigView.

Źródło: opracowanie własne

Do większości badań w tej pracy wykorzystano sygnały pozyskane z czujników znajdujących się w hipokampie. Liczba kanałów zlokalizowanych w tej części mózgu różniła się w zależności

od pacjenta. Dodatkowo, w późniejszej części badań wykorzystano dane z następujących obszarów mózgu: ciało migdałowate, kora śródwęczowa, heterotopia, zakręt przyhipokampowy, wyspa przednia, a także z istoty białej.

PySigView - analiza wizualna

Aplikacją, która posłużyła do wizualnej analizy dostępnych danych był PySigView. Jej rozwój jest ukierunkowany głównie na EEG, ale technicznie każdy sygnał może być zwizualizowany za jej pomocą. Dzięki wykorzystywaniu GPU do działania jest ona w stanie wyświetlać sygnały o wysokiej częstotliwości w szerokim oknie czasowym. Zarówno rysunek 3.3, jak i 3.4 pochodzą właśnie z tej aplikacji.

3.3.2. Identyfikacja zdarzeń epileptycznych w sygnałach iEEG

W przypadku badań nad funkcjami mózgu takimi jak pamięć, wykrywanie i usuwanie aktywności epileptycznej pozwala na izolację procesów neuronalnych, które są bezpośrednio związane z badanymi funkcjami, a nie są efektem stanu epileptycznego. Pozwala to także na generalizację wyników badań do osób niecierpiących na tę chorobę.

Autorzy zbioru danych dołączyli do swojej pracy repozytorium na portalu GitHub. Repozytorium to zawiera skrypt w języku Python do automatycznego wykrywania międzynapadowych wyładowań padaczkowych. Sposób działania tego detektora oraz dokładny opis problemów związanych z zagadnieniem został opisany przez autorów zbioru danych w publikacji naukowej [9].

Nagrania stereoEEG zostały podzielone na segmenty podczas procesu wstępnej obróbki i przygotowania danych treningowych dla modeli. Segmenty z aktywnością epileptyczną zostały oznaczone i wykluczone z dalszej analizy.

3.3.3. Ekstrakcja fragmentów sygnałów związanych z enkodowaniem

Dla każdego pacjenta i każdej sesji zadań typu FR w zbiorze danych znajduje się plik zawierający ręcznie oznaczone przez specjalistów informacje dotyczące wykrytych zdarzeń. Do zdarzeń należą między innymi momenty enkodowania oraz dekodowania pamięci. Dla każdego z tych momentów dostępne następujące informacje:

- onset: początek zdarzenia wyrażony jako czas, który upłynął od początku trwania nagrania,
- duration: czas trwania zdarzenia,
- sample: identyfikator próbki oznaczonej jako początek sygnału,
- trial type: Typ zdarzenia: enkodowanie, dekodowanie, dystraktor lub odliczanie,
- text: konkretne słowo, przedstawione pacjentowi do zapamiętania,
- word id: unikalny identyfikator słowa,

- list: identyfikator listy do której należy słowo (słowa były prezentowane pacjentowi w 12 elementowych listach).

Każde ze zdarzeń enkodowania pamięci zostało wyselekcjonowane z dostępnych sygnałów na podstawie wyżej wymienionych informacji. Pozostała część nagrań nie została użyta w dalszej części badań.

3.3.4. Dobór szerokości fragmentu

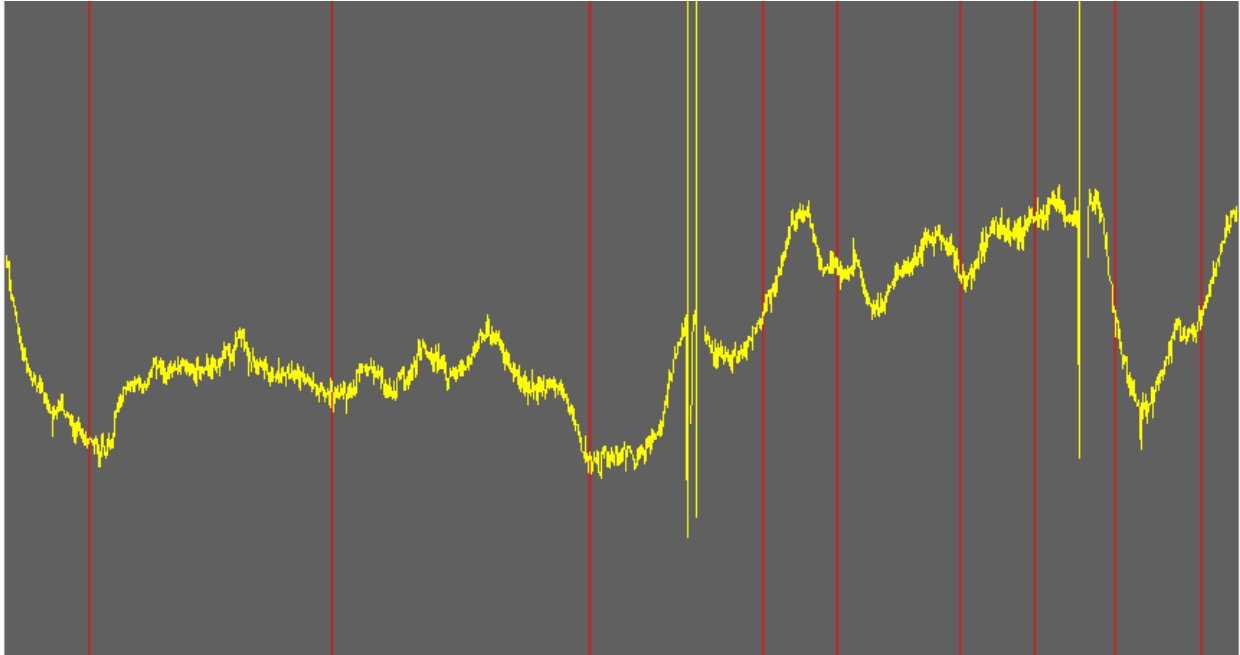
Długość wyciętych fragmentów była stała dla każdego ze zdarzeń. Została ona ustalona 1.5 sekundy, na które składało się 400ms sygnału przed zdarzeniem oraz 1100ms po oznaczonym początku zdarzenia. Wartości te dawały najlepsze wyniki badań i zostały dobrane empirycznie.

3.3.5. Tworzenie etykiet wydarzeń

Skuteczność enkodowania prezentowanych pacjentowi słów sprawdzono poprzez zestawienie wydarzeń enkodowania z wydarzeniami dekodowania (przypominania). W przypadku, gdy zdarzeniu enkodowania konkretnego słowa odpowiadało zdarzenie dekodowania, do odpowiadającego fragmentu sygnału dodawano etykietę o wartości 1. W przeciwnym wypadku fragment etykietowano wartością 0.

3.3.6. Eliminacja artefaktów związanych z mruganiem i uwarunkowaniami klinicznymi

Sygnały dotyczące średnicy źrenicy zawierały artefakty wynikające z mrugania. Dodatkowo momenty, w których pacjenci kierowali spojrzenie poza obszar ekranu, zostały potraktowane jako brakujące próbki. Rysunek 3.4 przedstawia fragment takiego sygnału przed obróbką.



Rysunek 3.4: Odczyt średnicy źrenicy zawierający artefakty powstałe z mruganiem.

Źródło: opracowanie własne

Wycinanie artefaktów

Przy każdym mrugnięciu wartość kilku kolejnych próbek rosła do nierzeczywistej wartości, następnie sygnał urywał się na kilka milisekund. Te krótkie przerwy wykorzystano do identyfikacji mrugnięć oka odbijających się na jakości sygnału, by następnie wyciąć pięć poprzedzających go próbek, co pozwoliło usunąć artefakty objawiające się nienaturalnie dużymi wartościami.

Interpolowanie przerw w sygnałach

W celu wyeliminowania przerw w sygnale zostały one wypełnione poprzez interpolację liniową między najbliższymi próbkami na każdym końcu luki. Pozwoliło to uzyskać sygnał ciągły.

3.3.7. Zmniejszenie częstotliwości próbkowania

Sygnały sEEG zostały zarejestrowane z częstotliwością próbkowania wynoszącą 32 kHz. W celu ułatwienia dalszej części badań wartość tą zmniejszono do 1000 Hz, co pozwoliło znacznie zmniejszyć objętość danych, jednocześnie znacząco nie tracąc informacji zawartych w nagraniach. Sygnały dotyczące odczytów źrenicy pozostawiono w pierwotnej częstotliwości 150 Hz.

3.3.8. Normalizacja Z-score


Normalizacja Z-score, uznana technika standaryzacji, jest stosowana, aby zminimalizować wpływ różnic w odczytach między pacjentami. Dane sEEG są często zróżnicowane pod względem amplitudy i skali. Dzięki normalizacji dane zostają przekształcone do postaci, w której średnia jest równa 0, a odchylenie standardowe jest równe 1. Metoda ta poprawia porównywalność sygnałów, minimalizuje wpływ zakłóceń takich jak szumy zewnętrzne na analizę, a także poprawia wydajność modeli uczenia maszynowego.

3.3.9. Filtrowanie danych

W badaniach nad zdolnościami poznawczymi najbardziej przydatne są cechy ekstraktowane z fal mózgu o niskiej częstotliwości: theta (4–9 Hz), alpha (9–16 Hz) oraz beta (16–25 Hz) [31]. Niechciane składowe sygnałów o wysokiej częstotliwości mogą zostać usunięte poprzez "wygładzenie" danych za pomocą filtra dolnoprzepustowego. W tym celu zastosowano powszechnie używany w tym zagadnieniu filtr Butterwortha. Dodatkową zaletą zastosowania filtra jest zredukowanie szumów mogących pochodzić z różnych źródeł, takich jak sprzęt, zakłócenia sieciowe czy artefakty biologiczne (np. ruchy oczu, aktywność mięśni).

Popularność wspomnianego filtra wynika z jego płaskiej charakterystyki częstotliwościowej w pasmie przepustowym i łagodnej charakterystyki tłumienia w pasmie zaporowym. Intensywność tłumienia może zostać dostosowana przez zmianę stopnia wielomianu w funkcji transferowej filtra, gdzie wyższy stopień powoduje szybsze tłumienie, co ilustruje Rysunek 3.5.

Ideal Frequency Response for a Butterworth




Rysunek 3.5: Wpływ stopnia wielomianu na tłumienie sygnału w pasmie zaporowym

Źródło: <https://www.electronics-tutorials.ws/filter/filter8.html>

Wyniki filtracji sygnału sEEG dla różnych wartości progu przepustowości zostały zaprezentowane na Rysunku 3.6. W przypadku filtracji danych w tym zbiorze sygnałów stopień

wielomianu został dobrany empirycznie na podstawie osiągnięć modeli.



Rysunek 3.6: Wygląd sygnału sEEG po zastosowaniu filtra dolnoprzepustowego w zależności od wysokości odcięcia. Od góry odpowiednio: brak filtra, 15Hz, 10Hz, 2.5Hz.

Źródło: opracowanie własne

4. Implementacja i trening modeli uczenia maszynowego.

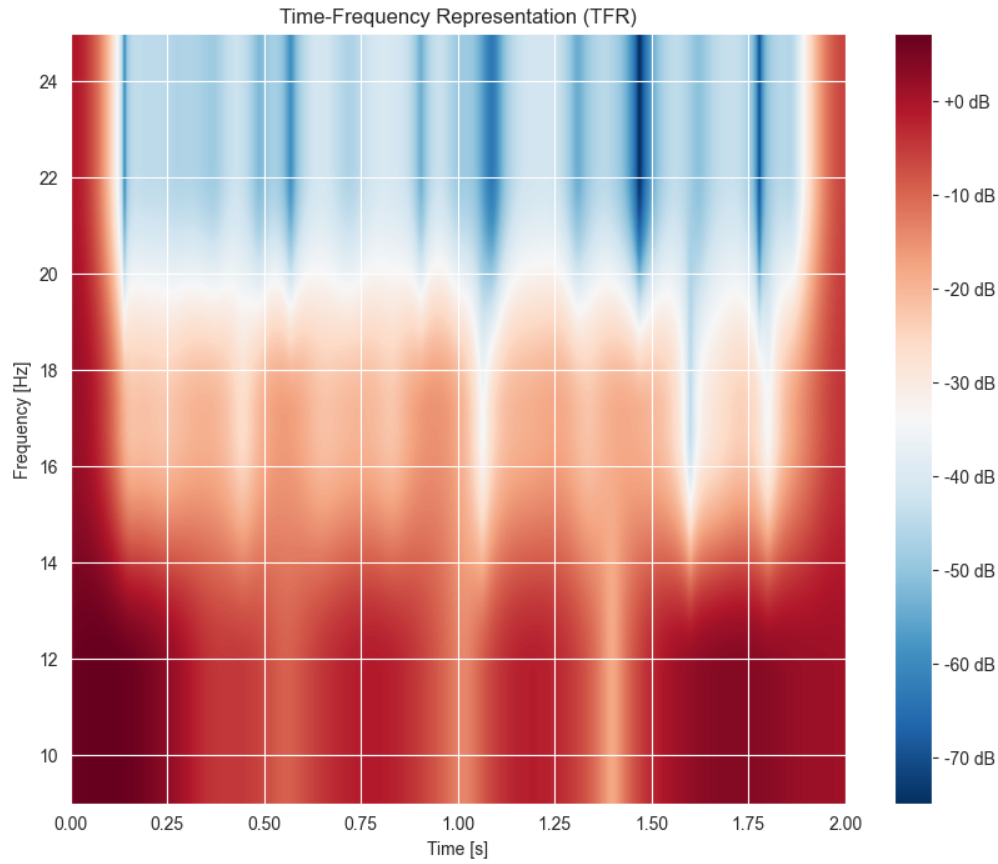
Ten rozdział opisuje sposób treningu modeli uczenia maszynowego, a także dodatkowe kroki podjęte przed wprowadzeniem danych do algorytmów, które przełożyły się na osiągnięcie lepszych wyników klasyfikacji.

4.1. Dobór i ekstrakcja cech

Ekstrakcja cech jest techniką pozwalającą na redukcję danych do zestawu cech, które są najbardziej znaczące dla badanego zjawiska. Odpowiednio dobrane i wydobyte z danych cechy dostarczają modelom istotnych informacji, co pozwala na efektywną naukę wzorców i zależności w sygnałach.

4.1.1. StereoEEG

Ekstrakcja cech w przypadku analizy sygnałów sEEG polegała na rozbiciu surowego sygnału na poszczególne komponenty, konkretnie moc w różnych zakresach częstotliwości. Na sygnałach sEEG zastosowano transformację falkową Morleta. Zadanie to obejmowało zdefiniowanie częstotliwość próbkowania, pasm częstotliwości oraz liczby cykli. Liczba cykli wpływa na zdolność do rozróżniania zdarzeń, które występują blisko siebie w czasie, oraz do rozróżniania różnych częstotliwości. Analiza skupiała się na falach theta (4–9 Hz), alpha (9–16 Hz) oraz beta (16–25 Hz). Implementacja funkcji znajdowała się w bibliotece MNE [15]. Kolejnym krokiem było przeliczenie mocy sygnału na wartość bezwzględną, a następnie konwersja wyników na skalę decybelową, powszechnie stosowaną przy analizie widma mocy. Wynikiem tych operacji była przetransformowanie sygnałów do reprezentacji czasowo-częstotliwościowej, widocznej na Rysunku 4.1.



Rysunek 4.1: Reprezentacja czasowo-częstotliwościowa fragmentu sygnału sEEG.

Źródło: opracowanie własne

4.1.2. Pupilometria

Opracowano trzy różne metody ekstrakcji cech z danych dotyczących średnicy źrenic pacjentów w czasie wykonywania sesji zadaniowych. Pierwsza metoda oparła się na wyliczeniu średniej, wariancji, kurtozy, a także współczynnika skośności dla następujących po sobie kroków czasowych. Drugie podejście także oparło się na podejściu statystycznym do badanych sygnałów, poprzez wyliczenie średniej, kwartyli oraz maksymalnej i minimalnej średnicy źrenicy w zadanym oknie czasowym. Ostatnim podejściem, które przełożyło się na najlepsze wyniki klasyfikacji, było podejście analizy czasowo częstotliwościowej i zastosowanie na danych transformacji falkowej Morleta.

4.2. Trening modeli

W tej sekcji przedstawiono proces selekcji danych do treningu, użyte w eksperymencie modele uczenia maszynowego oraz zastosowane metody balansowania i standaryzacji danych.

4.2.1. Balansowanie liczebności klas

Balansowanie liczebności klas w zbiorze danych ułatwia trening algorytmów, ponieważ pomaga zapobiegać tendencyjności modelu w stosunku do jednej klasy. Po zbalansowaniu danych model nie będzie już faworyzował klasy większościowej tylko dlatego, że zawiera więcej danych. Dane użyte do badań w tej pracy posiadały dwie klasy. Fragmenty sygnałów w momencie enkodowania pamięci zostały poetykietowane w zależności od zdolności pacjenta do przypomnienia sobie konkretnych słów w trakcie sesji zadaniowej. Sukces skutkował oznaczeniem fragmentu wartością 1, a porażka 0. Około 35% sygnałów przypisano wartość pozytywną. Do zbalansowania tej dysproporcji użyto metodę SMOTE (ang. Synthetic Minority Oversampling Technique) [34].

4.2.2. Standaryzacja danych

Standaryzacja zbioru danych jest powszechnym wymogiem dla wielu estymatorów uczenia maszynowego. Modele te mogą dawać niesatysfakcjonujące wyniki, jeżeli poszczególne atrybuty nie wykazują charakterystyk zbliżonych do standardowego rozkładu normalnego.

Po doborze i ekstrakcji cech przeprowadzono standaryzację danych zarówno dla sygnałów sEEG jak i tych z pupilometrii przy pomocy biblioteki scikit-learn [34].

4.2.3. Dobór modeli

W badaniach zastosowano trzy modele uczenia maszynowego: regresję logistyczną, SVM (ang. Support Vector Machines) oraz MLP (ang. Multilayer Perceptron). Istotnym warunkiem przy wyborze modeli była ich zdolność do analizy szeregów czasowych. Z uwagi na stosunkowo małą ilość danych nie zdecydowano się na zastosowanie bardziej zaawansowanych rodzajów sieci neuronowych, takich jak LSTM, czy Transformer.

4.2.4. Dane treningowe

W pracy badano skuteczność badań sEEG i pupilometrii jako biomarkerów do predykcji skutecznego enkodowania pamięci w ludzkim mózgu. Utworzono dwa podzbiory danych. Pierwszy z nich zawierał sygnały sEEG rejestrowane w hipokampie, drugi zebrał sygnał określający rozmiar źrenic pacjentów. Hipokamp jest kluczową częścią mózgu dla zdolności do tworzenia nowych wspomnień, zarówno tych związanych z faktami (tzw. pamięć deklaratywna lub jawna), jak i tych związanych z wydarzeniami (tzw. pamięć epizodyczna). Hipokamp pomaga również "odtwarzać" te wspomnienia, kiedy są one potrzebne. Wspomniane podzbiory danych posłużyły do treningu i testowania modeli uczenia maszynowego. Porównanie oraz opis osiągnięć algorytmów znajduje się w rozdziale piątym.

W trakcie badań porównano zdolność generalizacji modeli poprzez zestawienie ich sprawności zarówno dla poszczególnych pacjentów, jak i zbioru zawierającego wszystkie dostępne dane.

4.2.5. Impakt lokalizacji elektrod w strukturze mózgu na efektywność algorytmów uczenia maszynowego

W celu zbadania potencjału poszczególnych części mózgu w badaniach nad pamięcią porównano wydajność modelu MLP w zależności od lokalizacji, z których zbierano nagrania sEEG. Przebadano osiągi modelu do sześciu zbiorów danych. Każdy z tych zbiorów tworzony był na sygnałach pochodzących z innej części mózgu, następnie zostawał dzielony na zbiory treningowy i testowy, by na końcu zostać wprowadzonym do modelu. Do przebadanych struktur mózgu należały: hipokamp, ciało migdałowate, kora przedhipokampalna, zakręt przyhipokampowy, heterotopia, przednia część wyspy oraz istota biała. Z wyjątkiem istoty białej, wszystkie wymienione struktury mózgu są ściśle związane z zachodzącymi w nim procesami pamięciowymi. Ze względu na indywidualne umiejscowienie elektrod u każdego pacjenta (dostosowane do potrzeb badań klinicznych) liczba kontaktów rejestrujących aktywność mózgu w danym regionie różniła się między pacjentami. W konsekwencji ilość danych treningowych nie była identyczna w poszczególnych badaniach.

5. Prezentacja i analiza wyników

Walidacja krzyżowa jest szczególnie przydatna, gdy mamy do czynienia z ograniczonym zestawem danych, umożliwiając efektywne wykorzystanie dostępnych próbek do oszacowania błędu generalizacji modelu na nieznanymi danych. Każdy wynik model uczenia maszynowego, który został podany w tym rozdziale, jest średnią wyliczoną na podstawie 10-krotnej walidacji krzyżowej.

5.1. Osiągi modeli uczenia maszynowego na danych sEEG

Tabela 5.1 prezentuje efektywność trzech modeli uczenia maszynowego w klasyfikacji poprawnego enkodowania pamięci na podstawie sygnałów sEEG. Efektywność modeli oceniana jest za pomocą dwóch metryk: dokładności (Acc) oraz pola pod krzywą ROC (AUC). Modele trenowano i testowano zarówno na pełnym zbiorze danych, jak i dla każdego pacjenta indywidualnie.

Podobnie jak w poprzednim przypadku, wydajność modeli różni się w zależności od badanych osób, co może wynikać z indywidualnych różnic w danych sEEG, ilości danych zarejestrowanych u poszczególnych pacjentów (ilości przeprowadzonych sesji), czy różnej ilości kontaktów elektrod w badanej strukturze mózgu - hipokampusie.

Rysunki 5.1 oraz 5.2 prezentują macierz konfuzji, oraz wykresy krzywej ROC dla każdego z badanych modeli. Na ich podstawie zauważono tendencję modeli LR i SVM do klasyfikacji sygnałów fałszywie pozytywnie. Model MLP także wykazywał tę tendencję, choć już w mniejszym stopniu.


W każdym z analizowanych przypadków model sieci neuronowej typu MLP demonstruje najwyższe wartości metryki AUC, co sugeruje jego wyższą efektywność w kontekście klasyfikacji na bazie przedmiotowego zestawu danych.

Biorąc pod uwagę skomplikowany proces obróbki danych oraz złożoność aktywności neuronalnej podczas zadań poznawczych, wydajność modeli jest satysfakcjonująca. Osiągnięto zbliżone wyniki klasyfikacji do wyników przedstawionych w publikacjach naukowych takich jak oraz [39] dla analogicznego problemu, a także znacząco lepsze niż w przypadku [10], czy [1] dla tego samego problemu. Należy jednak pamiętać, że różnice w wynikach klasyfikacji mogą wynikać z faktu pracy na innych zbiorach danych, a także różnych podejść do przeprowadzania sesji eksperymentalnej podczas nagrań.

Tabela 5.1: Wydajność modeli szkolonych na pełnym zbiorze danych, oraz "per subject"(sEEG, hipokampus).


Subject	LR Acc	LR AUC	SVM Acc	SVM AUC	MLP Acc	MLP AUC
sub-003	62.536	0.6415	63.023	0.6479	64.9003	0.7122
sub-004	61.827	0.6131	62.846	0.6111	60.883	0.6342
sub-005	74.163	0.7939	73.742	0.7910	78.1825	0.8498
sub-007	98.447	1.0	98.143	1.0	96.268	0.9987
sub-009	82.323	0.8752	83.277	0.8809	84.050	0.9400
sub-011	94.887	0.9930	95.043	0.9931	96.75	0.9999
sub-012	92.1622	0.9815	92.1621	0.9822	94.054	0.9883
All	80.785	0.8152	81.221	0.8002	82.599	0.8885

Źródło: Opracowanie własne.



Rysunek 5.1: Macierz konfuzji dla modeli LR, SVM oraz MLP (sEEG, pełny zbiór danych, hipokampus).

Źródło: opracowanie własne.



Rysunek 5.2: Wykresy krzywej ROC (AUC) dla modeli LR, SVM oraz MLP (sEEG, pełny zbiór danych, hipokampus).

Źródło: opracowanie własne.

5.2. Osiągi modeli uczenia maszynowego na danych z pupilometrii

Badania osiągnięć modeli trenowanych na danych z pupilometrii objęły te same typy modeli oraz metryki co w przypadku treningu na sEEG. W tym wypadku przewaga MLP nad LR i SVM nie była tak bezwzględna, co podsumowuje tabela 5.2. Dla trójki pacjentów MLP osiągnęło mniejszą dokładność od 2 pozostałych modeli. Mimo mniejszej dokładności tylko w jednym wypadku metryka AUC wskazywała na niekorzyść MLP, zazwyczaj działając mocno

na korzyść tego modelu.


Ucząc model na pełnym zbiorze danych, osiągnięto wyniki odpowiednio 78.5% dokładności oraz 0.82 AUC. W porównaniu z modelami korzystającymi z danych sEEG, skuteczność predykcji była tylko nieznacznie mniejsza. Były to odpowiednio 4 punkty procentowe dla dokładności oraz 0.06 wartości AUC. Matryce konfuzji oraz wykresy krzywej ROC dla każdego z trzech zbadanych modeli zostały przedstawione na rysunkach 5.3 oraz 5.4.

Bezpośrednie porównanie uzyskanych wyników z innymi publikacjami naukowymi jest niemożliwe, ponieważ nie istnieją dotychczas prace, które zastosowałyby metody uczenia maszynowego do przewidywania wyników pamięciowych na podstawie danych pochodzących z pupilometrii.

Tabela 5.2: Wydajność modeli szkolonych na pełnym zbiorze danych, oraz "per-subject" (pupilometria)


Subject	LR Acc	LR AUC	SVM Acc	SVM AUC	MLP Acc	MLP AUC
sub-003	74.347	0.7671	77.490	0.7841	70.771	0.7344
sub-004	60.064	0.5698	59.794	0.5584	56.52564	0.6149
sub-005	68.797	0.6946	70.556	0.6971	70.2472	0.7631
sub-007	92.225	0.9114	91.600	0.9180	95.009	0.9890
sub-009	81.137	0.8645	82.936	0.8396	89.087	0.9425
sub-011	94.295	0.9855	94.901	0.9858	97.896	0.9920
sub-012	81.673	0.8391	83.612	0.8134	85.317	0.9256
All	65.794	0.6957	66.644	0.6903	78.452	0.8294

Źródło: Opracowanie własne.



Rysunek 5.3: Macierz konfuzji dla modeli LR, SVM oraz MLP (pupilometria, pełny zbiór danych).

Źródło: opracowanie własne.



Rysunek 5.4: Wykresy krzywej ROC (AUC) dla modeli LR, SVM oraz MLP (pupilometria, pełny zbiór danych).

Źródło: opracowanie własne.

5.3. Wydajność modelu MLP w zależności od regionu mózgu, z którego pozyskano dane

Tabela 5.3 przedstawia efektywność modelu MLP w predykcji, wykorzystującego sygnały sEEG zarejestrowane w różnych regionach mózgu pacjentów. Ze względu na to, że lokalizacja elektrod różniła się między pacjentami, dodatkowym czynnikiem do rozważenia podczas analizy wyników jest liczba pacjentów, których dane uwzględniono w procesie treningu i testowania algorytmów. Skuteczność modelu jest oceniana na podstawie dwóch wskaźników:


dokładności i AUC.

Tabela 5.3: Wydajność modeli szkolonych na sygnałach z poszczególnych struktur mózgu (sEEG, pełny zbiór danych)

Region	Accuracy	AUC	Number of Subjects
Hippocampus	82.599	0.8885	7
Amygdala	82.249	0.8785	5
Entorhinal Cortex	71.009	0.7461	2
Parahippocampal Gyrus	87.650	0.9230	3
Heterotopia	79.3318	0.8604	3
Anterior Insula	83.080	0.8817	5
White Matter	67.138	0.7243	7

Źródło: Opracowanie własne.

Wyniki podkreślają, że skuteczność modelu MLP w analizie danych SEEG pod względem predykcji skutecznego enkodowania pamięci może się różnić w zależności od regionu mózgu. Jest on najskuteczniejszy w zakręcie przyhipokampalnym, podczas gdy wyniku treningu na danych zebranych z istoty białej, wykazywały najniższą dokładność i AUC spośród wszystkich regionów, z wartościami odpowiednio 67,138% i 0,7243. Było to oczekiwane, jako że w procesach mózgu związanych z pamięcią, istota biała ma dużo mniejsze znaczenie niż struktury takie jak hipokamp, czy zakręt przyhipokampalny.



Rysunek 5.5: Dokładność modelu MLP w zależności od struktury mózgu, z którego pozyskano dane

Źródło: opracowanie własne.

6. Wnioski końcowe

W niniejszej pracy dyplomowej dokonano szeroko zakrojonego badania w kontekście rozważania zastosowania pupilometrii i elektroencefalografii jako biomarkerów w badaniach nad procesem zapamiętywania. Różne eksperymenty i analizy wykazały szereg cennych wniosków.

Spośród sześciu badanych struktur mózgu, najbardziej owocne okazały się dane zarejestrowane w zakręcie przyhipokampalnym pacjentów. Należy jednak pamiętać, że procesy pamięciowe obejmują wiele interakcji między regionami, co nie zostało przebadane w tej pracy. Być może stosunkowo niskie koszty pozyskania danych z pupilometrii, w porównaniu z badaniami sEEG, wpłyną na większą ilość badań w tym temacie, co z kolei zaowocuje lepszym zrozumieniem procesów neuronalnych leżących u podstaw procesów pamięciowych.

Potwierdzono, że monitorowanie rozmiaru źrenicy z wysoką rozdzielczością dostarcza nowego biomarkera do badania procesu zapamiętywania. Biomarker ten jest komplementarny do obecnie stosowanych pomiarów aktywności mózgu, a jednocześnie oferuje zalety w postaci łatwego dostępu i solidności. Co więcej, modele uczenia maszynowego, które zostały wytrenowane w ramach tej pracy, wykazały się zadowalającą zdolnością do generalizacji pomiędzy różnymi pacjentami.

Dodatkowo zaobserwowano bardzo duży wpływ doboru badanych częstotliwości fal mózgowych na zdolności modeli uczenia maszynowego do klasyfikacji sygnałów.

Zakres prac obejmował opracowanie następujących kroków:

- Przeprowadzenie analizy literatury na temat procesów enkodowania pamięci, pupilometrii i stereoEEG oraz zastosowania uczenia maszynowego w tych obszarach.
- Pozyskanie i wstępne przygotowanie danych.
- Rozpoznanie i odrzucenie sygnałów zarejestrowanych podczas aktywności epileptycznej w danych z sEEG.
- Konstrukcja i optymalizacja modeli.
- Trenowanie i ewaluacja modeli.
- Przeprowadzenie analiza porównawczej.
- Interpretacja i prezentacja wyników.
- Sformułowanie wniosków.

6.1. Obszar potencjalnego zastosowania pracy

Praca ta porównując użyteczność sEEG i pupilometrii jako biomarkerów do badań nad kodowaniem pamięci posiada spektrum zastosowań zarówno w sferze akademickiej, jak i praktycznej. Badania te mogą dostarczyć cennych informacji dla badaczy zajmującymi się procesami enkodowania pamięci. Wyniki badań mogą być również istotne dla projektantów interfejsów człowiek-komputer, którzy mogą chcieć wykorzystać sEEG lub pupilometrię do tworzenia skutecznych systemów. Wyniki pracy mogą również mieć zastosowanie w kontekście edukacyjnym, pośrednio pomagając zrozumieć, jak różne czynniki wpływają na nasze zdolności zapamiętywania, co może prowadzić do stworzenia bardziej skutecznych strategii nauczania.

6.2. Przyszłe kierunki badań

W perspektywie przyszłych prac możliwe są następujące kierunki badań:

- Wykorzystanie filtracji przestrzennej (ang. spatial filtering) dla poprawy jakości analizowanych sygnałów.
- Zastosowanie zaawansowanych algorytmów selekcji cech, takich jak dwukierunkowa analiza wariancji (two-way ANOVA), co może przyczynić się do wyjaśnienia związku między pomiarami średnicy źrenicy a pomiarami elektrofizjologicznymi będzie miało kluczowe znaczenie dla lepszego zrozumienia tych biomarkerów i mechanizmów mózgowych w przetwarzaniu pamięci.
- Wykorzystanie Generative Adversarial Networks (GANs) do generowania większej ilości próbek, co z kolei może poprawić zdolność generalizacji modeli.
- Eksploracja możliwości sieci typu Transformer specjalizowanych dla danych EEG [48], w połączeniu z techniką transfer learning.
- Zastosowanie Time-frequency Time-space LSTM [35] - innowacyjnych architektur sieci neuronowych skonstruowanych specjalnie do analizy sygnałów fizjologicznych, również w parze z transfer learning.

Każdy z tych kierunków stanowi możliwość rozszerzenia obecnych badań i otwiera nowe perspektywy dla przyszłych prac.

Bibliografia

- [1] A. Arora, J.-J. Lin, A. Gasperian, J. Maldjian, J. Stein, M. Kahana, and B. Lega. Comparison of logistic regression, support vector machines, and deep learning classifiers for predicting memory encoding success using human intracranial eeg recordings. *Journal of neural engineering*, 15(6):066028, 2018.
- [2] T. Bafna and J. P. Hansen. Mental fatigue measurement using eye metrics: A systematic literature review. *Psychophysiology*, 58(6):e13828, 2021.
- [3] S. Balci, M. Sabuncu, J. Yoo, S. Ghosh, S. Whitfield-Gabrieli, J. Gabrieli, and P. Golland. Prediction of successful memory encoding from fmri data. In *Medical image computing and computer-assisted intervention: MICCAI... International Conference on Medical Image Computing and Computer-Assisted Intervention*, volume 2008, page 97. NIH Public Access, 2008.
- [4] H. C. Barron, R. Auksztulewicz, and K. Friston. Prediction and memory: A predictive coding account. *Progress in neurobiology*, 192:101821, 2020.
- [5] A. Bueno, J. Sato, and M. Hornberger. Eye tracking—the overlooked method to measure cognition in neurodegeneration? *Neuropsychologia*, 133:107191, 2019.
- [6] D. Chaluvadi, T. D. Reddy, D. S. Pavan, and B. R. Prathap. Machine learning techniques for detecting and forecasting disorders in children using pupillometry data. *Journal of Algebraic Statistics*, 13(1):612–620, 2022.
- [7] J. Cimbalnik. Zenodo, (2019). Last accessed 28 May 2023.
- [8] J. Cimbalnik, J. Dolezal, Ç. Topçu, M. Lech, V. S. Marks, B. Joseph, M. Dobias, J. Van Gompel, G. Worrell, and M. Kuciewicz. Intracranial electrophysiological recordings from the human brain during memory tasks with pupillometry. *Scientific Data*, 9(1):6, 2022.
- [9] J. Cimbalnik, P. Klimes, V. Sladky, P. Nejedly, P. Jurak, M. Pail, R. Roman, P. Daniel, H. Guragain, B. Brinkmann, et al. Multi-feature localization of epileptic foci from interictal, intracranial eeg. *Clinical Neurophysiology*, 130(10):1945–1953, 2019.
- [10] M. Derner, A. Jahanbekam, C. Bauckhage, N. Axmacher, and J. Fell. Prediction of memory formation based on absolute electroencephalographic phases in rhinal cortex and hippocampus outperforms prediction based on stimulus-related phase shifts. *European Journal of Neuroscience*, 47(7):824–831, 2018.
- [11] A. K. Engel, C. K. Moll, I. Fried, and G. A. Ojemann. Invasive recordings from the human brain: clinical insights and beyond. *Nature Reviews Neuroscience*, 6(1):35–47, 2005.

-
- [12] Y. Ezzyat, J. E. Kragel, J. F. Burke, D. F. Levy, A. Lyalenko, P. Wanda, L. O'Sullivan, K. B. Hurley, S. Busygin, I. Pedisich, et al. Direct brain stimulation modulates encoding states and memory performance in humans. *Current biology*, 27(9):1251–1258, 2017.
 - [13] A. Famili, G. Krishnan, E. Davenport, J. Germi, B. Wagner, B. Lega, and A. Montillo. Automatic identification of successful memory encoding in stereo-eeg of refractory, mesial temporal lobe epilepsy. In *2017 IEEE 14th International Symposium on Biomedical Imaging (ISBI 2017)*, pages 587–590. IEEE, 2017.
 - [14] I. Fried, U. Rutishauser, M. Cerf, and G. Kreiman. *Single neuron studies of the human brain: probing cognition*. MIT Press, 2014.
 - [15] A. Gramfort, M. Luessi, E. Larson, D. A. Engemann, D. Strohmeier, C. Brodbeck, R. Goj, M. Jas, T. Brooks, L. Parkkonen, and M. S. Hämäläinen. MEG and EEG data analysis with MNE-Python. *Frontiers in Neuroscience*, 7(267):1–13, 2013.
 - [16] M. S. Hermiller, Y. F. Chen, T. B. Parrish, and J. L. Voss. Evidence for immediate enhancement of hippocampal memory encoding by network-targeted theta-burst stimulation during concurrent fmri. *Journal of Neuroscience*, 40(37):7155–7168, 2020.
 - [17] J. Hermiz, N. Rogers, E. Kaestner, M. Ganji, D. R. Cleary, B. S. Carter, D. Barba, S. A. Dayeh, E. Halgren, and V. Gilja. Sub-millimeter ecog pitch in human enables higher fidelity cognitive neural state estimation. *NeuroImage*, 176:454–464, 2018.
 - [18] S. Jun, J. S. Kim, and C. K. Chung. Prediction of successful memory encoding based on lateral temporal cortical gamma power. *Frontiers in Neuroscience*, 15:517316, 2021.
 - [19] J. Kalafatovich, M. Lee, and S.-W. Lee. Decoding declarative memory process for predicting memory retrieval based on source localization. *Plos one*, 17(9):e0274101, 2022.
 - [20] V. Kremen, J. J. Duque, B. H. Brinkmann, B. M. Berry, M. T. Kucewicz, F. Khadjevand, J. Van Gompel, M. Stead, E. K. St Louis, and G. A. Worrell. Behavioral state classification in epileptic brain using intracranial electrophysiology. *Journal of neural engineering*, 14(2):026001, 2017.
 - [21] M. T. Kucewicz, J. Dolezal, V. Kremen, B. M. Berry, L. R. Miller, A. L. Magee, V. Fabian, and G. A. Worrell. Pupil size reflects successful encoding and recall of memory in humans. *Scientific reports*, 8(1):4949, 2018.
 - [22] C.-L. Lee, W. Pei, Y.-C. Lin, A. Granmo, and K.-H. Liu. Emotion detection based on pupil variation. In *Healthcare*, volume 11, page 322. MDPI, 2023.
 - [23] B. C. Lega, J. Jacobs, and M. Kahana. Human hippocampal theta oscillations and the formation of episodic memories. *Hippocampus*, 22(4):748–761, 2012.
 - [24] S. D. Lhatoo, P. Kahane, and H. O. Lüders. *Invasive studies of the human epileptic brain: Principles and practice*. Oxford University Press, 2018.

- [25] J. A. Livezey, K. E. Bouchard, and E. F. Chang. Deep learning as a tool for neural data analysis: speech classification and cross-frequency coupling in human sensorimotor cortex. *PLoS computational biology*, 15(9):e1007091, 2019.
- [26] D. Lu and J. Triesch. Residual deep convolutional neural network for eeg signal classification in epilepsy. *arXiv preprint arXiv:1903.08100*, 2019.
- [27] S. Mathôt, J. Fabius, E. Van Heusden, and S. Van der Stigchel. Safe and sensible preprocessing and baseline correction of pupil-size data. *Behavior research methods*, 50:94–106, 2018.
- [28] D. P. McMullen, G. Hotson, K. D. Katyal, B. A. Wester, M. S. Fifer, T. G. McGee, A. Harris, M. S. Johannes, R. J. Vogelstein, A. D. Ravitz, et al. Demonstration of a semi-autonomous hybrid brain-machine interface using human intracranial eeg, eye tracking, and computer vision to control a robotic upper limb prosthetic. *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, 22(4):784–796, 2013.
- [29] M. R. Mercier, A.-S. Dubarry, F. Tadel, P. Avanzini, N. Axmacher, D. Cellier, M. Del Vecchio, L. S. Hamilton, D. Hermes, M. J. Kahana, et al. Advances in human intracranial electroencephalography research, guidelines and good practices. *NeuroImage*, page 119438, 2022.
- [30] M. R. Mercier, A.-S. Dubarry, F. Tadel, P. Avanzini, N. Axmacher, D. Cellier, M. D. Vecchio, L. S. Hamilton, D. Hermes, M. J. Kahana, R. T. Knight, A. Llorens, P. Megevand, L. Melloni, K. J. Miller, V. Piai, A. Puce, N. F. Ramsey, C. M. Schwiedrzik, S. E. Smith, A. Stolk, N. C. Swann, M. J. Vansteensel, B. Voytek, L. Wang, J.-P. Lachaux, and R. Oostenveld. Advances in human intracranial electroencephalography research, guidelines and good practices. *NeuroImage*, 260:119438, 2022.
- [31] N. Mirchi, N. Warsi, F. Zhang, S. M. Wong, H. Suresh, K. Mithani, L. Erdman, and G. Ibrahim. Decoding intracranial eeg with machine learning: A systematic review. *Frontiers in Human Neuroscience*, page 399, 2022.
- [32] T. Pailla, K. J. Miller, and V. Gilja. Autoencoders for learning template spectrograms in electrocorticographic signals. *Journal of neural engineering*, 16(1):016025, 2019.
- [33] I. M. Pavisic, Y. Pertzov, J. M. Nicholas, A. O’Connor, K. Lu, K. X. Yong, M. Husain, N. C. Fox, and S. J. Crutch. Eye-tracking indices of impaired encoding of visual short-term memory in familial alzheimer’s disease. *Scientific reports*, 11(1):8696, 2021.
- [34] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [35] T. D. Pham. Time-frequency time-space lstm for robust classification of physiological signals. *Scientific reports*, 11(1):6936, 2021.

- [36] A. Rajkomar, J. Dean, and I. Kohane. Machine learning in medicine. *New England Journal of Medicine*, 380(14):1347–1358, 2019.
- [37] M. Rashid, M. Islam, N. Sulaiman, B. S. Bari, R. K. Saha, and M. J. Hasan. Electrocor-ticography based motor imagery movements classification using long short-term memory (lstm) based on deep learning approach. *SN Applied Sciences*, 2:1–7, 2020.
- [38] B. W. Rotenberg, C. F. George, K. M. Sullivan, and E. Wong. Wait times for sleep apnea care in ontario: a multidisciplinary assessment. *Canadian respiratory journal*, 17(4):170–174, 2010.
- [39] K. V. Saboo, Y. Varatharajah, B. M. Berry, V. Kremen, M. R. Sperling, K. A. Davis, B. C. Jobst, R. E. Gross, B. Lega, S. A. Sheth, et al. Unsupervised machine-learning classification of electrophysiologically active electrodes during human cognitive task performance. *Scientific reports*, 9(1):17390, 2019.
- [40] J. Schrouff, J. Mourão-Miranda, C. Phillips, and J. Parvizi. Decoding intracranial eeg data with multiple kernel learning method. *Journal of neuroscience methods*, 261:19–28, 2016.
- [41] M. Subathra, M. A. Mohammed, M. S. Maashi, B. Garcia-Zapirain, N. Sairamya, and S. T. George. Detection of focal and non-focal electroencephalogram signals using fast walsh-hadamard transform and artificial neural network. *Sensors*, 20(17):4952, 2020.
- [42] N. Suthana and I. Fried. Deep brain stimulation for enhancement of learning and memory. *Neuroimage*, 85:996–1002, 2014.
- [43] T. Syeda-Mahmood. Role of big data and machine learning in diagnostic decision support in radiology. *Journal of the American College of Radiology*, 15(3):569–576, 2018.
- [44] F. Tadel, S. Baillet, J. C. Mosher, D. Pantazis, and R. M. Leahy. Brainstorm: a user-friendly application for meg/eeg analysis. *Computational intelligence and neuroscience*, 2011:1–13, 2011.
- [45] T. M. Thomas, D. N. Candrea, M. S. Fifer, D. P. McMullen, W. S. Anderson, N. V. Thakor, and N. E. Crone. Decoding native cortical representations for flexion and extension at upper limb joints using electrocorticography. *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, 27(2):293–303, 2019.
- [46] Ç. Topçu, V. S. Marks, K. V. Saboo, M. Lech, P. Nejedly, V. Kremen, G. A. Worrell, and M. T. Kucewicz. Hotspot of human verbal memory encoding in the left anterior prefrontal cortex. *EBioMedicine*, 82:104135, 2022.
- [47] W4n. Biblioteka do pracy na formacie danych bids, (2023). Last accessed 28 May 2023.
- [48] Z. Wan, M. Li, S. Liu, J. Huang, H. Tan, and W. Duan. Eegformer: A transformer-based brain activity classification method using eeg signal. *Frontiers in Neuroscience*, 17, 2023.

- [49] P. Wang, T. M. Berzin, J. R. G. Brown, S. Bharadwaj, A. Becq, X. Xiao, P. Liu, L. Li, Y. Song, D. Zhang, et al. Real-time automatic detection system increases colonoscopic polyp and adenoma detection rates: a prospective randomised controlled study. *Gut*, 68(10):1813–1819, 2019.
- [50] R. Zemblys, D. C. Niehorster, O. Komogortsev, and K. Holmqvist. Using machine learning to detect events in eye-tracking data. *Behavior research methods*, 50:160–181, 2018.
- [51] B. Zhu, M. Farivar, and M. Shoaran. Resot: Resource-efficient oblique trees for neural signal classification. *IEEE Transactions on Biomedical Circuits and Systems*, 14(4):692–704, 2020.

Spis rysunków

2.1	Podkategorie iEEG	5
2.2	Wzrost liczby publikacji dotyczących iEEG w latach 1975-2015	6
2.3	Udział poszczególnych typów algorytmów uczenia maszynowego w analizie danych z badań iEEG.	8
2.4	Podział algorytmów uczenia maszynowego	9
2.5	Udział poszczególnych typów algorytmów uczenia maszynowego w analizie danych z badań iEEG.	12
3.1	Schemat konwersji danych do ostatecznej struktury.	21
3.2	Przegląd zestawu zadań wykonywanych przez pacjentów. SP – smooth pursuit, FR – free recall, AS – anti-pro saccade, PAL - paired-associate learning.	24
3.3	Odczyt średnicy źrenicy oka niskiej jakości, zawierający dużą ilość artefaktów. Zrzut ekranu został zrobiony w programie PySigView.	25
3.4	Odczyt średnicy źrenicy zawierający artefakty powstałe z mruganiem.	28
3.5	Wpływ stopnia wielomianu na tłumienie sygnału w pasmie zaporowym	29
3.6	Wygląd sygnału sEEG po zastosowaniu filtra dolnoprzepustowego w zależności od wysokości odcięcia. Od góry odpowiednio: brak filtra, 15Hz, 10Hz, 2.5Hz.	30
4.1	Reprezentacja czasowo-częstotliwościowa fragmentu sygnału sEEG.	32
5.1	Macierz konfuzji dla modeli LR, SVM oraz MLP (sEEG, pełny zbiór danych, hipokampus).	36
5.2	Wykresy krzywej ROC (AUC) dla modeli LR, SVM oraz MLP (sEEG, pełny zbiór danych, hipokampus).	37
5.3	Macierz konfuzji dla modeli LR, SVM oraz MLP (pupilometria, pełny zbiór danych).	38
5.4	Wykresy krzywej ROC (AUC) dla modeli LR, SVM oraz MLP (pupilometria, pełny zbiór danych).	39
5.5	Dokładność modelu MLP w zależności od struktury mózgu, z którego pozyskano dane	41

Spis tabel

3.1	Przegląd całkowitej liczby zadań i zapisów z elektrod u poszczególnych pacjentów.	22
5.1	Wydajność modeli szkolonych na pełnym zbiorze danych, oraz "per subject"(sEEG, hipokampus).	36
5.2	Wydajność modeli szkolonych na pełnym zbiorze danych, oraz "per-subject"(pupilometria)	38
5.3	Wydajność modeli szkolonych na sygnałach z poszczególnych struktur mózgu (sEEG, pełny zbiór danych)	40